UNIVERSITY OF ATHENS
DEPARTMENT OF INFORMATICS AND TELECOMMUNICATIONS

Deep Learning for NLP

Student name: Αναστάσιος Ιγγλεζάκης *sdi: sdi2300054*

Course: *Artificial Intelligence II (M138, M226, M262, M325)*
Semester: *Spring Semester 2025*

Contents

1 Abstract 2

2 Data processing and analysis 2

2.1 Pre-processing 2

2.2 Vectorization 2

3 Algorithms and Experiments 3

3.0.1 Trial Tables 3

3.1 Hyper-parameter tuning 28

3.2 Optimization techniques 29

3.3 Evaluation 29

4 Results and Overall Analysis 30

4.1 Results Analysis 30

4.1.1 Best trial 30

4.2 Comparison with the first project 33

4.3 Comparison with the second project 33

1. Abstract

Στόχος της παρούσας εργασίας είναι η ανάπτυξη ενός συστήματος ταξινόμησης συναισθήματος για ένα σύνολο από tweets, αξιοποιώντας τις αρχιτεκτονικές των transformers BERT και DistilBERT και εφαρμόζοντας fine-tuning, μέσω πειραμάτων. Το πρόβλημα αντιμετωπίζεται ως binary classifiation, με τις ετικέτες να αντιστοιχούν σε θετικό ή αρνητικό συναίσθημα.

Αρχικά εφαρμόζεται προεπεξεργασία του κειμένου, με μετατροπή χαρακτήρων σε πεζά και κανονικοποίηση της γλώσσας, ώστε να διαμορφωθούν καθαρές είσοδοι για τα transformer models. Για την είσοδο στα μοντέλα χρησιμοποιούνται οι προκαθορισμένοι tokenizers των BERT και DistilBERT, με padding και truncation για σταθερό μήκος ακολουθιών.

Ακολουθεί προσαρμογή των παραμέτρων των μοντέλων πάνω στο training set, με παρακολούθηση της απόδοσης στο validation set και χρήση τεχνικών όπως, learning rate, schedulers και επιλογή κατάλληλου batch size, με στόχο τη σταθερή και αποδοτική εκπαίδευση χωρίς overfitting. Για κάθε μοντέλο υλοποιούνται πειράματα με εναλλαγές υπερπαραμέτρων (learning rate, weight decay, batch size) και αξιολογούνται οι επιδόσεις μέσω των μετρικών accuracy, precision, recall και F1-score. Παράλληλα, γίνεται απεικόνιση των learning curves, ROC curve και confusion matrices για την κατανόηση της συμπεριφοράς του κάθε μοντέλου. Τέλος, τα αποτελέσματα υποβάλλονται στο Kaggle για αξιολόγηση στο test set, και συγκρίνονται οι τελικές επιδόσεις των BERT και DistilBERT.

2. Data processing and analysis

2.1. Pre-processing

Η συνάρτηση clean_text υλοποιεί την προεπεξεργασία των tweets, με στόχο τη διατήρηση της συντακτικής και σημασιολογικής πληροφορίας, η οποία είναι κρίσιμη για την κατανόηση από τα transformer μοντέλα. Πιο συγκεκριμένα, κάθε tweet υφίσταται επέκταση των αγγλικών συντομογραφιών μέσω της βιβλιοθήκης contractions (π.χ. “don’t” → “do not”), καθώς και κανονικοποίηση επαναλαμβανόμενων γραμμάτων (π.χ. “soooo” → “soo”) μέσω της συνάρτησης reduce_repeated_letters. Η διαδικασία αυτή στοχεύει στον περιορισμό της σημασιολογικής ασάφειας χωρίς να αλλοιώνεται η πρόταση.

Σε αντίθεση με άλλες κλασικές μεθόδους, δεν αφαιρούνται σημεία στίξης, mentions, hashtags ή emojis, καθώς τέτοια στοιχεία μπορούν να εμπεριέχουν πληροφορία χρήσιμη για το sentiment, για την οποία τα μοντέλα BERT και distilBERT είναι καλώς προσαρμοσμένα. Επίσης, ενώ ορίστηκε λεξικό με συχνές slang εκφράσεις, τελικά δεν εφαρμόστηκε στην παρούσα υλοποίηση. Η τελική έξοδος είναι ένα καθαρισμένο αλλά πλήρες string, κατάλληλο για tokenization από το tokenizer του BERT και του DistilBERT. Η ίδια διαδικασία εφαρμόστηκε ενιαία σε train, validation και test set, ώστε να διατηρείται η συνέπεια μεταξύ των συνόλων.

2.2. Vectorization

Η μετατροπή των tweets σε μορφή κατάλληλη για είσοδο στο μοντέλο πραγματοποιείται μέσω του προκαθορισμένου tokenizer του BERT και του DistilBERT (distilbert-base-uncased). Για κάθε κείμενο εφαρμόζεται tokenization με χρήση padding και truncation σε μέγιστο μήκος 40 tokens, σύμφωνα με την παράμετρο MAX_LEN, η οποία επιλέχθηκε κατόπιν στατιστικής ανάλυσης της κατανομής του

μήκους των tweets που εκτελείται στον κώδικα. Ο tokenizer μετατρέπει το καθαρισμένο κείμενο σε διανύσματα input_ids και attention_mask,
όπου τα input_ids αντιστοιχούν σε ακέραιους δείκτες λέξεων από το λεξιλόγιο του μοντέλου και το attention_mask υποδεικνύει ποια tokens είναι πραγματικά και ποια αποτελούν padding.

Τα διανύσματα αυτά αποτελούν την είσοδο του transformer, όπου κάθε token αναπαρίσταται μέσω προεκπαιδευμένων embeddings. Η διαδικασία vectorization είναι πλήρως ενσωματωμένη στην αρχιτεκτονική των BERT και DistilBERT και δεν απαιτεί εξωτερική επεξεργασία.. Δεν εφαρμόζεται επιπλέον επεξεργασία στα embeddings, καθώς κατά τη διάρκεια του fine-tuning προσαρμόζονται οι τελευταίες στρώσεις του μοντέλου για την εκτέλεση του task της ταξινόμησης συναισθήματος.

3. Algorithms and Experiments

3.0.1. Trial Tables. Τα πειράματα έγιναν όλα με εκπαίδευση σε 3 epochs. Ωστόσο, οι μετρικές που παρουσιάζονται δεν αναφέρονται πάντα στο τελευταίο epoch , αλλά στο epoch που παραχώρησε την μεγαλύτερη ευστοχία στο validation, το οποίο ήταν το δεύτερο epoch σε αρκετά πειράματα.

Trial	Learning Rate	Batch Size	Weight Decay	Hidden Dropout	Attention Dropout	Classification Dropout	Scheduler
1	2e-5	16	-	-	-	-	Linear With Warmup
2	2e-5	32	-	-	-	-	Linear With Warmup
3	2e-5	64	-	-	-	-	Linear With Warmup
4	2e-5	96	-	-	-	-	Linear With Warmup
5	1e-5	96	-	-	-	-	Linear With Warmup
6	4e-5	96	-	-	-	-	Linear With Warmup
7	1e-4	96	-	-	-	-	Linear With Warmup
8	4e-5	96	-	-	-	-	Linear With Warmup
9	4e-5	96	0.15	0.15	0.15	0.15	Linear With Warmup
10	4e-5	96	0.01	0.15	0.15	0.15	Linear With Warmup
11	4e-5	96	0.06	0.3	0.15	0.15	Linear With Warmup
12	4e-5	96	0.06	0.05	0.15	0.15	Linear With Warmup
13	4e-5	96	0.06	0.15	0.3	0.15	Linear With Warmup
14	4e-5	96	0.06	0.15	0.05	0.15	Linear With Warmup
15	4e-5	96	0.06	0.15	0.15	0.3	Linear With Warmup
16	4e-5	96	0.06	0.15	0.15	0.05	Linear With Warmup
17	4e-5	96	0.06	0.15	0.15	0.15	CAWR
18	4e-5	96	0.06	0.15	0.15	0.15	Reduce LR on Plateu

Table 1: Παράμετροι πειραμάτων BERT

Trial	Phase	Loss	Accuracy	F1	Recall	Precision
1	Train	0.1928	0.9341	0.9341	0.9341	0.9341
1	Validation	0.4871	0.8530	0.8530	0.8530	0.8530
2	Train	0.2830	0.8827	0.8827	0.8827	0.8827
2	Validation	0.3495	0.8526	0.8526	0.8526	0.8533
3	Train	0.2931	0.8769	0.8769	0.8769	0.8769
3	Validation	0.3345	0.8546	0.8546	0.8546	0.8546

4	Train	0.3014	0.8723	0.8723	0.8723	0.8723
4	Validation	0.3396	0.8541	0.8547	0.8547	0.8547
5	Train	0.2935	0.8761	0.8761	0.8761	0.8761
5	Validation	0.3537	0.8514	0.8514	0.8514	0.8514
6	Train	0.2757	0.8860	0.8860	0.8860	0.8860
6	Validation	0.3422	0.8554	0.8554	0.8557	0.8554
7	Train	0.2744	0.8873	0.8873	0.8873	0.8873
7	Validation	0.3518	0.8496	0.8496	0.8496	0.8496
8	Train	0.2825	0.8814	0.8814	0.8814	0.8814
8	Validation	0.3490	0.8559	0.8559	0.8559	0.8559
9	Train	0.2825	0.8814	0.8814	0.8814	0.8814
9	Validation	0.3490	0.8559	0.8559	0.8559	0.8559
10	Train	0.2977	0.8747	0.8747	0.8747	0.8747
10	Validation	0.3390	0.8552	0.8551	0.8552	0.8552
11	Train	0.2744	0.8873	0.8873	0.8874	0.8873
11	Validation	0.3518	0.8496	0.8496	0.8496	0.8506
12	Train	0.2668	0.8909	0.8909	0.8910	0.8910
12	Validation	0.3455	0.8548	0.8547	0.8548	0.8548
13	Train	0.3139	0.8656	0.8656	0.8656	0.8656
13	Validation	0.3408	0.8534	0.8540	0.8540	0.8540
14	Train	0.2872	0.8802	0.8802	0.8802	0.8802
14	Validation	0.3409	0.8553	0.8553	0.8553	0.8553
15	Train	0.2979	0.8747	0.8747	0.8747	0.8747
15	Validation	0.3409	0.8535	0.8535	0.8535	0.8535
16	Train	0.2985	0.8739	0.8739	0.8740	0.8740
16	Validation	0.3389	0.8550	0.8554	0.8550	0.8556
17	Train	0.2849	0.8811	0.8811	0.8811	0.8811
17	Validation	0.3529	0.8525	0.8525	0.8525	0.8525
18	Train	0.2977	0.8935	0.8752	0.8752	0.8752
18	Validation	0.3529	0.8525	0.8525	0.8528	0.8525

Table 2: Μετρικές πειραμάτων BERT – Πειράματα BERT

1) Πείραμα 1

Στα πρώτα πειράματα δοκιμάστηκε μια απλή υλοποίηση του BERT στην οποία οι κύριες παράμετροι για πειραματισμό, ήταν το batch size και το learning rate. Ο εντοπισμός των καλύτερων τιμών αυτών των παραμέτρων μας οδηγεί στην ρύθμιση αυτών με τρόπο που εξασφαλίζει την καλύτερη συμπεριφορά μάθησης του μοντέλου. Σε αυτό το πείραμα δοκιμάζουμε την τιμή batch_size = 16 και την τιμή 2e-5 για το learning rate, μια κανονική τιμή για αυτόν τον transformer. Σε αυτό το πείραμα παρατηρείται μια σχετικά καλή επίδοση του μοντέλου, ωστόσο όμως υπάρχει η τάση για overfitting καθώς οι μετρικές του training είναι πολύ αυξημένες σε σχέση με τις αντίστοιχες μετρικές του validation. Loss και Learning Curve:

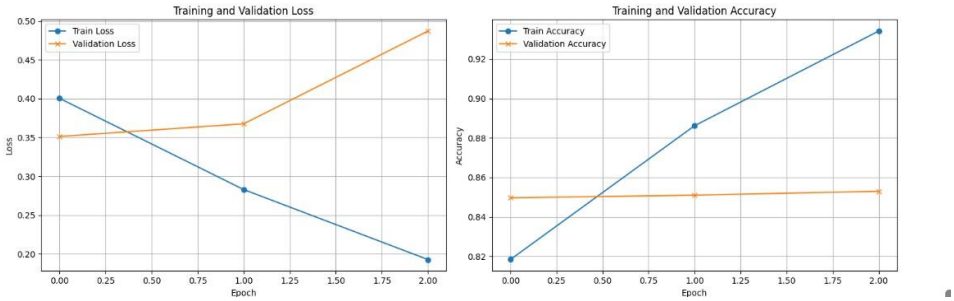

Figure 1: Πείραμα 1, Loss and Learning Curve

Confusion Matrix:

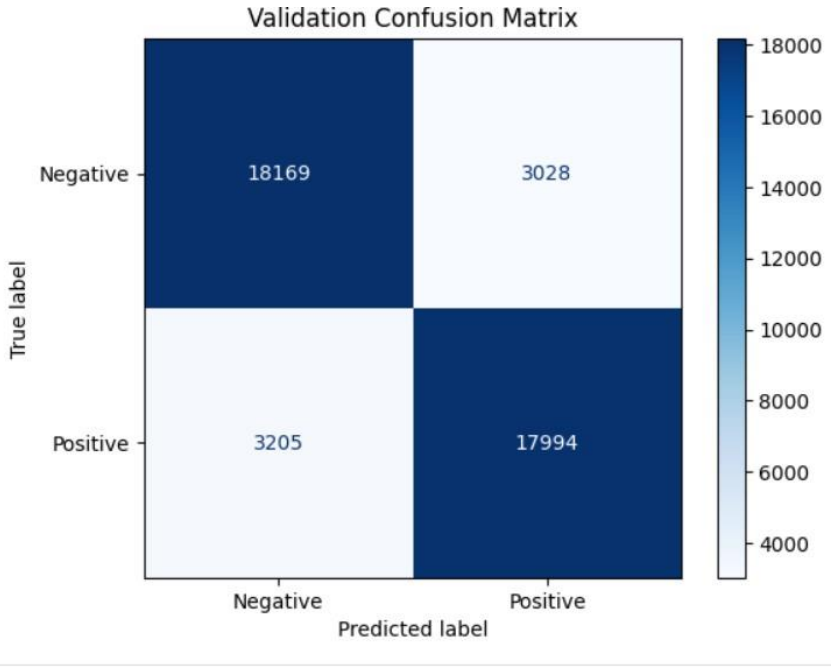

Figure 2: Πείραμα 1, Confusion Matrix

ROC curve:

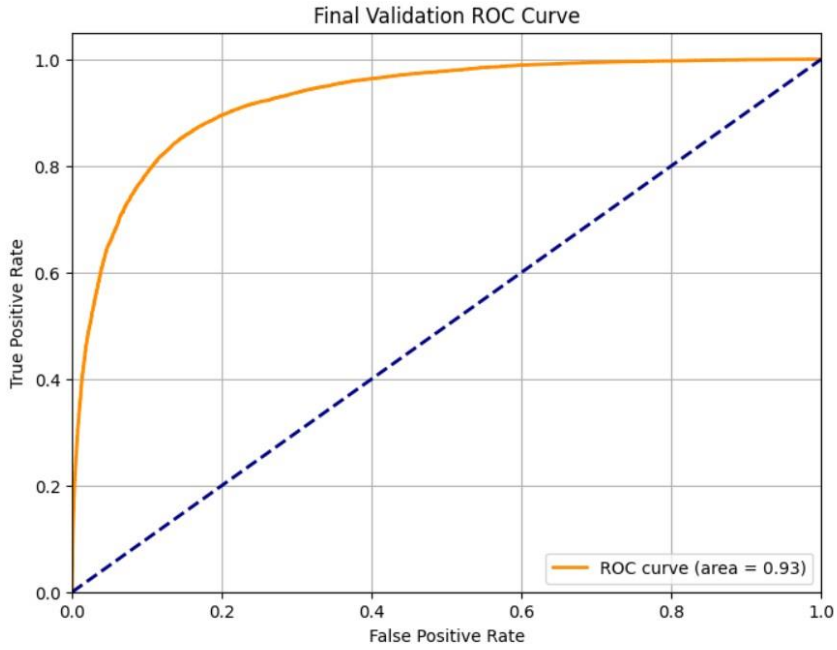

Figure 3: Πείραμα 1, ROC curve

2) Πείραμα 2

Σε αυτό το πείραμα δοκιμάζουμε την τιμή batch_size = 32 με σταθερή την τιμή 2e-5 για το learning rate. Σε αυτό το πείραμα το μοντέλο παρουιάζει αυξημένη επίδοση , και υπάρχει μικρότερη διαφορά μεταξύ training και validation σχετικά με τα metrics αυτών. Loss και Learning Curve:

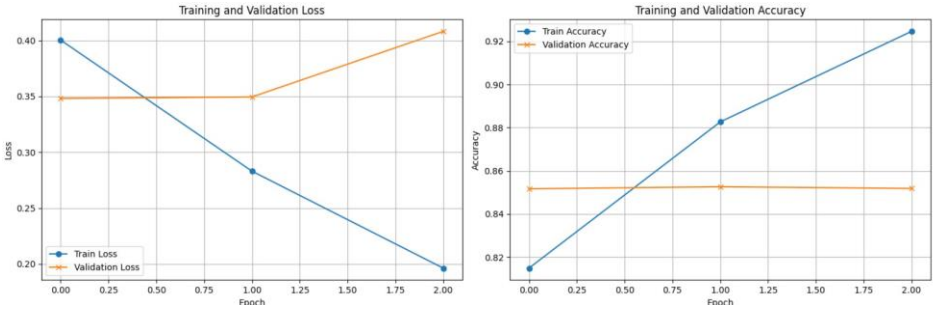

Figure 4: Πείραμα 2, Loss and Learning Curve

Confusion Matrix:

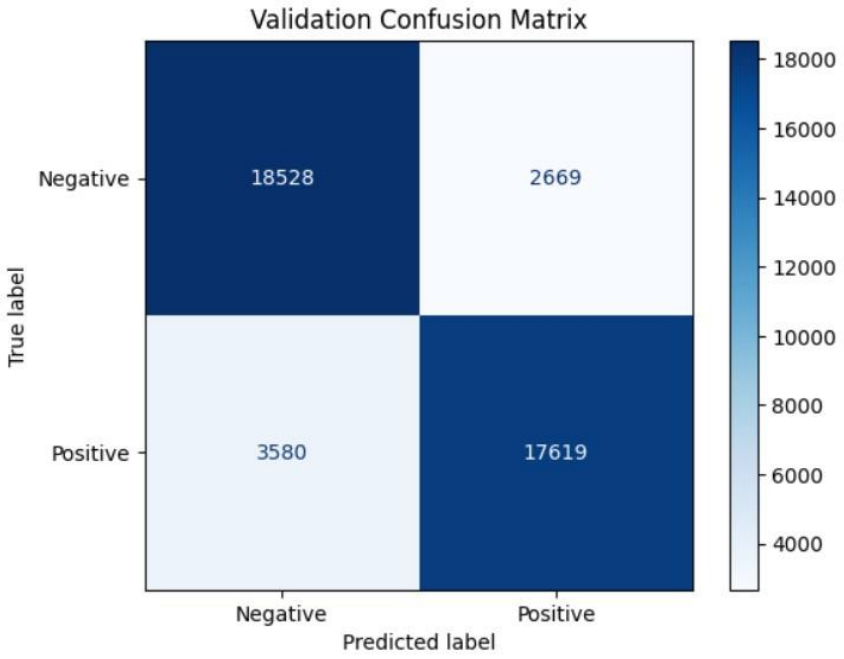

Figure 5: Πείραμα 2, Confusion Matrix

ROC curve:

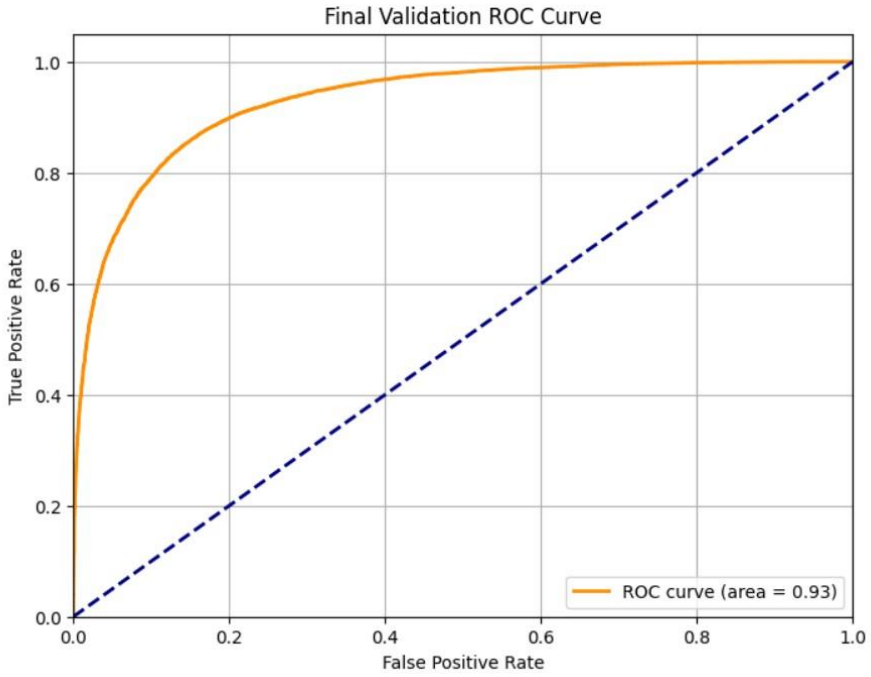

Figure 6: Πείραμα 2, ROC curve

3) Πείραμα 3

Εδώ δοκιμάζουμε την τιμή batch_size = 64 ίδια τιμή learning rate. Σε αυτό το πείραμα το μοντέλο παρουιάζει επίσης ακόμη πιο αυξημένη επίδοση κατά ένα μικρό διάστημα, και υπάρχει ακόμη μεγαλύτερη σύγκλιση μεταξύ επίδοσης στο training και το validation dataset.

Loss και Learning Curve:

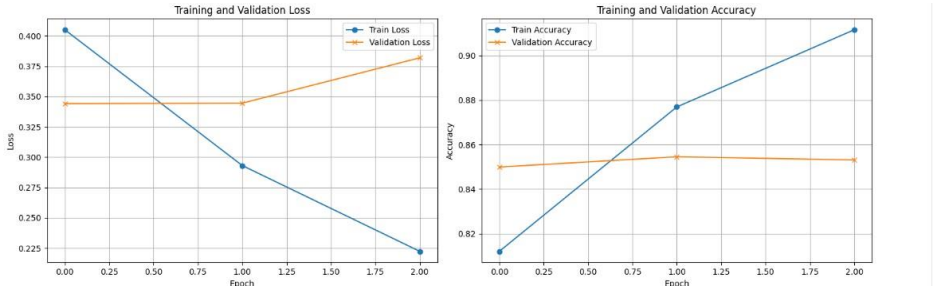

Figure 7: Πείραμα 3, Loss and Learning Curve

Confusion Matrix:

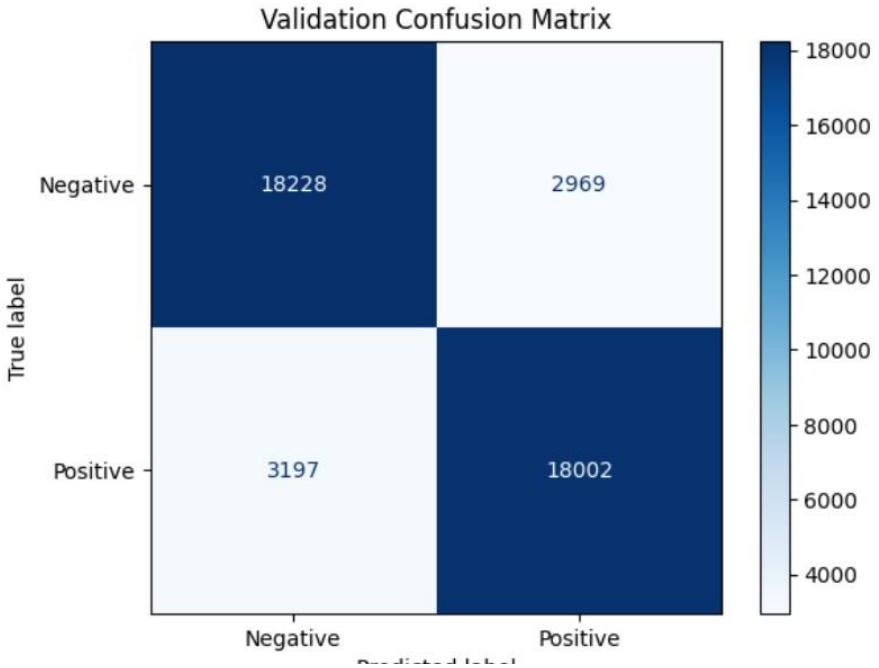

Figure 8: Πείραμα 3, Confusion Matrix

ROC curve:

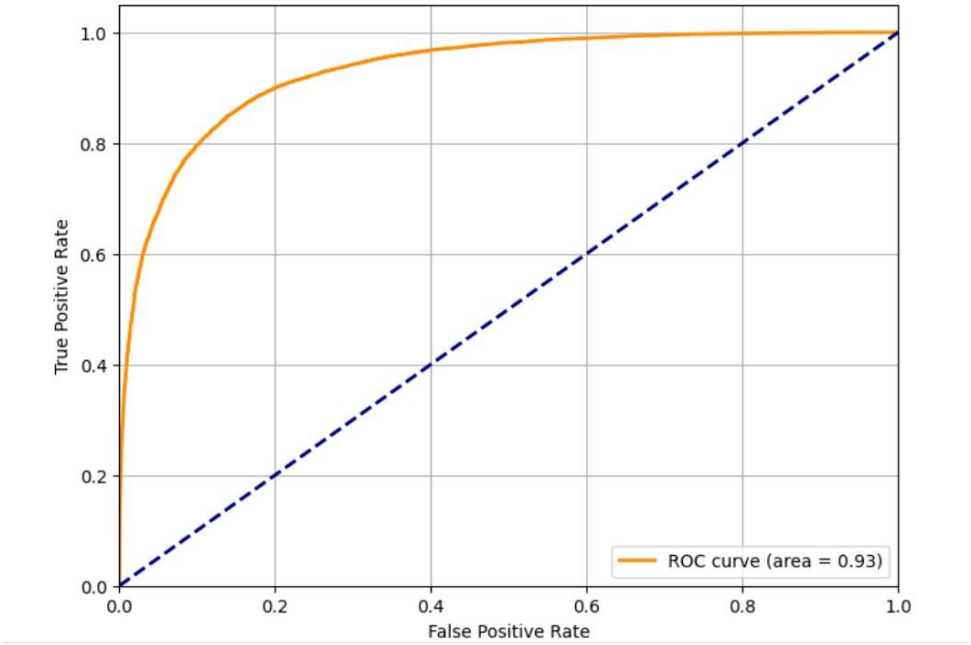

Figure 9: Πείραμα 3, ROC curve

4) Πείραμα 4

Αυξάνουμε ακόμη περισσότερο την τιμή batch_size, κάνοντάς το ίσο με 96. Σε αυτό το πείραμα το μοντέλο παρουιάζει την ίδια τάση με πριν, για σύγκλιση μεταξύ training και validation και για μικρή αύξηση επίδοσης. Loss και Learning Curve:

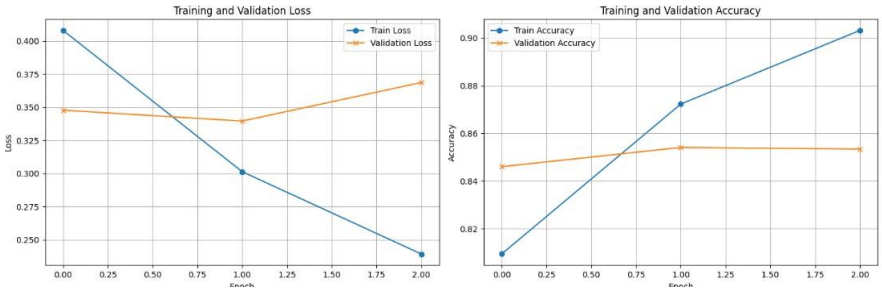

Figure 10: Πείραμα 4, Loss and Learning Curve

Confusion Matrix:

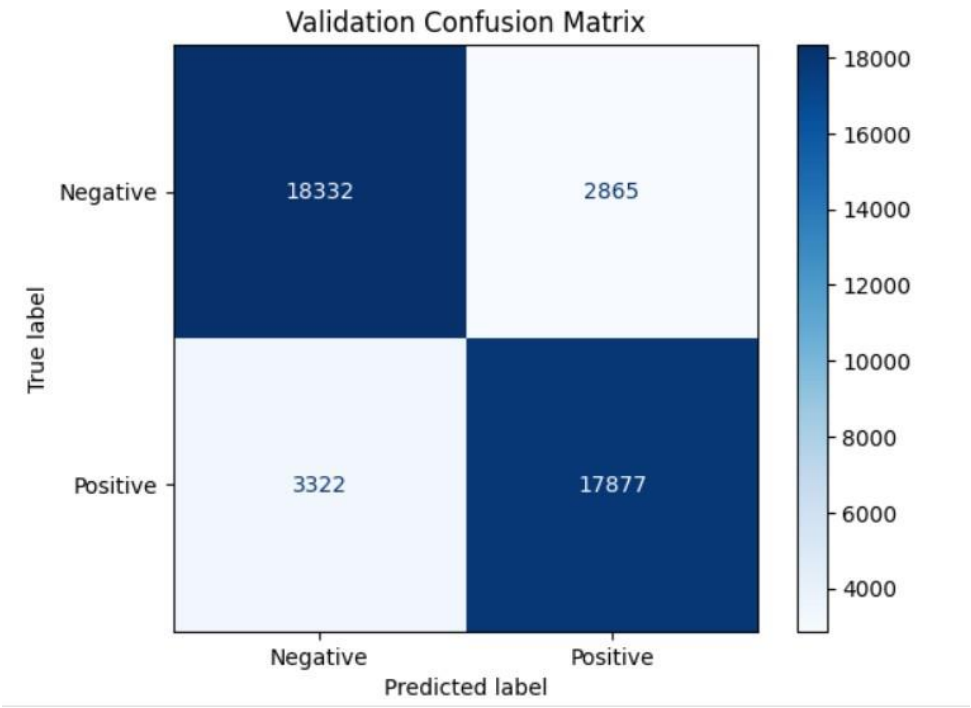

Figure 11: Πείραμα 4, Confusion Matrix

5) Πείραμα 5

Με βάση τα προηγούμενα πειράματα, διαπιστώθηκε ότι η τιμή batch_size = 96 οδηγεί σε σχετικά σταθερή εκπαίδευση και καλή απόδοση. Στο Πείραμα 5 εξετάζεται η επίδραση της μείωσης του learning rate από 2e-5 σε 1e-5, με στόχο να διερευνηθεί εάν η πιο "συγκρατημένη" μάθηση βελτιώνει τη γενίκευση στο validation set.

Παρατηρήθηκε ότι, ενώ η απόκλιση ανάμεσα σε training και validation metrics μειώθηκε στο τρίτο epoch συγκριτικά με τα προηγούμενα πειράματα, η συνολική απόδοση στο validation set (στο βέλτιστο epoch) δεν βελτιώθηκε σε σχέση με το Πείραμα 4. Συνεπώς, η μείωση του learning rate οδήγησε σε πιο σταθερή αλλά όχι αποδοτικότερη μάθηση. Δεδομένου ότι κρατούμε το καλύτερο epoch για κάθε πείραμα (συνήθως το δεύτερο), η παραμετροποίηση του
Πειράματος 4 παραμένει προτιμότερη.

Loss και Learning Curve:

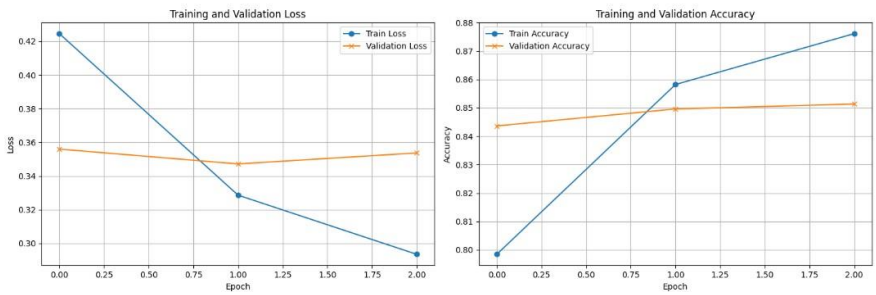

Figure 12: Πείραμα 5, Loss and Learning Curve

6) Πείραμα 6

Σε αυτό το πείραμα, εξετάζεται η επίδραση της αύξησης του learning rate σε 4e-5, διατηρώντας το batch_size = 96, το οποίο είχε αποδειχθεί σταθερό στα προηγούμενα πειράματα. Η αύξηση του ρυθμού μάθησης αποσκοπεί στη γρηγορότερη προσαρμογή του μοντέλου και ενδεχομένως σε καλύτερη αναζήτηση βέλτιστων βαρών.

Πράγματι, το μοντέλο εμφάνισε υψηλότερες μετρικές στο validation set, φτάνοντας τη μέγιστη τιμή F1-score μεταξύ όλων των πειραμάτων. Ωστόσο, παρατηρήθηκε πιο έντονη απόκλιση μεταξύ training και validation loss, γεγονός που δείχνει τάση προς overfitting, αν το μοντέλο λειτουργήσει για τρία epochs. Παρ' όλα αυτά, επειδή η τελική αξιολόγηση βασίζεται στην απόδοση στο validation set που έγινε στο καλύτερο epoch, δηλαδή το δεύτερο, η ρύθμιση learning rate = 4e-5 κρίθηκε ως η πλέον αποδοτική για τα επόμενα στάδια. Loss και Learning Curve:

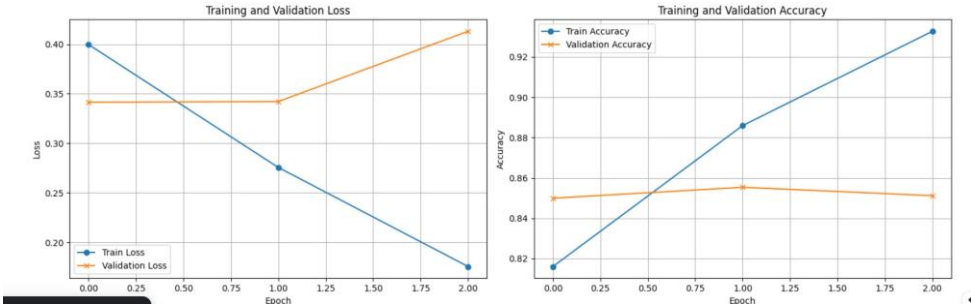

Figure 13: Πείραμα 6, Loss and Learning Curve

7) Πείραμα 7

Σε αυτό το πείραμα δοκιμάστηκε μια τελευταία μεγάλη τιμή για το Learning Rate, η 1e-4. Εδώ δεν υπήρξε ούτε καλύτερη συμπεριφορά μάθησης ούτε καλυτερη επίδοση. Επομένως απορρίπτεται αυτή η τιμή,

Loss και Learning Curve:

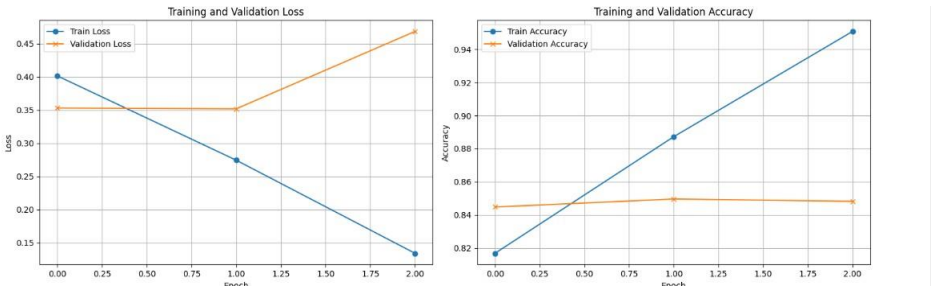

Figure 14: Πείραμα 7, Loss and Learning Curve

8) Πείραμα 8

Εδώ χρησιμοποιήσαμε το optuna, με το οποίο βρήκαμε κάποιες καλές ενδεικτικές τιμές για την ρύθμιση των παραμέτρων weight decay, attention dropout, classification dropout και hidden dropout.

Οι παράμετροι που ανεδείχθησαν ως οι καταλληλότερες ήταν: - weight_decay = 0.065 hidden_dropout = 0.15 - classifier_dropout = 0.15 - attention_dropout = 0.15

9) Πείραμα 9

Το Πείραμα 9 εφαρμόζει για πρώτη φορά τις τιμές υπερπαραμέτρων που προτάθηκαν μέσω του εργαλείου Optuna στο Πείραμα 8. Πιο συγκεκριμένα, χρησιμοποιούνται:

- weight decay = 0.15
- dropout = 0.15 σε όλα τα επίπεδα: hidden, attention και classification layers

Ο στόχος ήταν να ελεγχθεί αν αυτές οι τιμές μπορούν να προσφέρουν καλύτερη γενίκευση και σταθερότητα στην απόδοση του μοντέλου BERT.

Τα αποτελέσματα έδειξαν ότι η απόδοση στο *training set* ήταν ελαφρώς μειωμένη σε σχέση με προηγούμενα πειράματα, αλλά στο *validation set* το μοντέλο παρέμεινε ισχυρό:

- **F1-score** = 0.8559
- **Accuracy** = 0.8559

Αυτό υποδηλώνει ότι το *regularization* που προέκυψε από την εφαρμογή των dropouts και του weight decay συνέβαλε στην αποφυγή υπερπροσαρμογής, χωρίς να μειώσει την απόδοση στο validation. Οι τιμές αυτές υιοθετήθηκαν ως βάση για τα επόμενα πειράματα.

10) Πείραμα 10

Στο Πείραμα 10 εξετάζεται η επίδραση της μείωσης του **weight decay** από 0.15 σε 0.01, διατηρώντας τις ίδιες τιμές για τα dropouts (0.15). Η υπόθεση ήταν ότι μικρότερη «τιμωρία» στα βάρη θα επέτρεπε στο μοντέλο να μάθει καλύτερα, διατηρώντας παράλληλα τη γενίκευσή του στο validation set.

Ωστόσο, τα αποτελέσματα έδειξαν ότι η απόδοση του μοντέλου παρέμεινε ουσιαστικά σταθερή και δεν υπήρξε καμία αξιόλογη βελτίωση σε σχέση με το προηγούμενο πείραμα:

- **F1-score** = 0.8551
- **Accuracy** = 0.8552

Το training loss παρέμεινε επίσης παρόμοιο, γεγονός που δείχνει ότι η μείωση του regularization δεν είχε σημαντικό αντίκτυπο. Συνεπώς, η αρχική τιμή του weight decay (0.15) φαίνεται να είναι προτιμότερη, προσφέροντας ελαφρώς μεγαλύτερη σταθερότητα και καλύτερο έλεγχο υπερπροσαρμογής.

11) Πείραμα 11

Στο Πείραμα 11 δοκιμάζεται περαιτέρω μείωση του **weight decay** σε 0.06, διατηρώντας τις υπόλοιπες παραμέτρους ίδιες (dropout = 0.15, learning rate = 4e-5, batch size = 96). Η αλλαγή αυτή είχε ως στόχο να εξεταστεί αν μια πιο «ήπια» μορφή regularization μπορεί να οδηγήσει σε βελτίωση της απόδοσης, αποφεύγοντας υπερβολικό περιορισμό των βαρών.

Ωστόσο, τα αποτελέσματα έδειξαν ότι το μοντέλο εμφάνισε μικρή επιδείνωση σε σχέση με το Πείραμα 10:

- **F1-score** = 0.8496
- **Accuracy** = 0.8496

12) Πείραμα 12

Στο Πείραμα 12 διατηρείται το weight decay = 0.065, όπως και στο Πείραμα 11, αλλά γίνεται μείωση του **hidden dropout** από 0.3 σε 0.05, με στόχο τη μείωση της απώλειας πληροφορίας εντός των ενδιάμεσων στρώσεων του μοντέλου.

Η υπόθεση ήταν ότι το υψηλό dropout στις hidden layers ίσως οδηγούσε σε underfitting. Με τη μείωση του dropout:

- **F1-score** = 0.8547
- **Accuracy** = 0.8548

Το αποτέλεσμα δείχνει ελαφρώς καλύτερη απόδοση στο validation set σε σχέση με το Πείραμα 11. Αυτό ενισχύει την ιδέα ότι το υπερβολικό dropout στις ενδιάμεσες στρώσεις μπορεί να βλάπτει τη μάθηση.

13) Πείραμα 13

Στο Πείραμα 13 διατηρούνται οι τιμές learning rate = 4e-5, batch size = 96 και weight decay = 0.06, ενώ το **attention dropout** αυξάνεται από 0.15 σε 0.3. Η αλλαγή αυτή έχει στόχο να ελεγχθεί αν περισσότερο attention dropout βοηθά το μοντέλο να γενικεύει καλύτερα, αποτρέποντας την εξάρτηση από επιμέρους τοπικές συσχετίσεις. Ωστόσο, τα αποτελέσματα δεν παρουσίασαν βελτίωση:

- **F1-score** = 0.8540
- **Accuracy** = 0.8534

Το training accuracy μειώθηκε σημαντικά (0.8656), γεγονός που δείχνει ότι η αύξηση του attention dropout πιθανόν εμπόδισε την αποτελεσματική μάθηση. Συνεπώς, η αλλαγή αυτή οδήγησε σε υποβάθμιση της επίδοσης, και η αρχική τιμή 0.15 θεωρείται προτιμότερη για τη συγκεκριμένη υπερπαράμετρο.

14) Πείραμα 14

Στο Πείραμα 14, διατηρούνται σταθερές όλες οι βασικές παράμετροι (learning rate = 4e-5, batch size = 96, weight decay = 0.06), ενώ μειώνεται το **attention dropout** από
0.15 σε 0.05.

Το αποτέλεσμα ήταν ήπια θετικό:

- **F1-score** = 0.8553
- **Accuracy** = 0.8553

Η μικρή αυτή βελτίωση δείχνει ότι η προσαρμογή του attention dropout μπορεί να επηρεάσει τη συμπεριφορά του μοντέλου. Ωστόσο, η διαφορά είναι οριακή και οπότε η τιμή 0.15 παραμένει αξιόπιστη επιλογή.

15) Πείραμα 15

Στο Πείραμα 15 διατηρούνται όλες οι υπόλοιπες υπερπαράμετροι σταθερές, ενώ αυξάνεται το **classification dropout** από 0.15 σε 0.30. Η μεταβλητή αυτή ελέγχει την πιθανότητα τυχαίας απενεργοποίησης στη τελική στρώση ταξινόμησης, επομένως σχετίζεται άμεσα με την ικανότητα του μοντέλου να γενικεύει.

Ωστόσο, η απόδοση του μοντέλου μειώθηκε ελαφρώς:

- **F1-score** = 0.8535
- **Accuracy** = 0.8535

Η αύξηση του dropout φαίνεται ότι εισήγαγε υπερβολική τυχαιότητα, η οποία παρεμπόδισε την καλή εκμάθηση των χαρακτηριστικών που οδηγούν σε σωστή ταξινόμηση. Επομένως, η τιμή 0.15 για το classification dropout παραμένει πιο ισορροπημένη επιλογή.

16) Πείραμα 16

Στο Πείραμα 16 δοκιμάζεται η μείωση του **classification dropout** από 0.15 σε 0.05, με στόχο να διαπιστωθεί αν λιγότερο dropout στην τελική στρώση μπορεί να επιτρέψει στο μοντέλο να αποδώσει καλύτερα στην πρόβλεψη.

Το αποτέλεσμα ήταν ελαφρώς βελτιωμένο σε σχέση με το προηγούμενο πείραμα:

- **F1-score** = 0.8554
- **Accuracy** = 0.8550

Η μείωση του dropout πιθανόν βοήθησε το μοντέλο να αξιοποιήσει πληρέστερα τη δυναμική της τελικής στρώσης, οδηγώντας σε πιο σαφή όρια απόφασης. Παράλληλα, δεν παρατηρήθηκε έντονη τάση για overfitting. Επομένως, η μικρή τιμή dropout στην τελική στρώση μπορεί να θεωρηθεί επίσης αποδοτική σε αυτό το σημείο του μοντέλου.

17) Πείραμα 17

Στο Πείραμα 17 διατηρούνται οι ίδιες τιμές υπερπαραμέτρων όπως στο Πείραμα 16, αλλά αλλάζει το **scheduler**, από γραμμική μείωση (Linear Warmup) σε Cosine Annealing with Warm Restarts (CAWR). Ο στόχος είναι να εξεταστεί αν το κυκλικό σχήμα learning rate μπορεί να βοηθήσει την εκπαίδευση να ξεφύγει από τοπικά ελάχιστα και να βελτιώσει τη γενίκευση.

Τα αποτελέσματα δεν έδειξαν βελτίωση:

- **F1-score** = 0.8525
- **Accuracy** = 0.8525

Παρά το πιο σύνθετο σχήμα ρύθμισης του learning rate, η επίδοση υποχώρησε ελαφρώς σε σχέση με το Πείραμα 16 και δεν παρατηρήθηκε αποφυγή του overfitiing. Αυτό δείχνει ότι το συγκεκριμένο scheduler δεν παρείχε επιπλέον όφελος στο συγκεκριμένο setup, πιθανόν επειδή το training είχε ήδη σταθεροποιηθεί με το Linear Warmup.

18) Πείραμα 18

Στο Πείραμα 18 διατηρείται το ίδιο σύνολο υπερπαραμέτρων με τα Πειράματα 16 και 17, αλλά δοκιμάζεται μια διαφορετική στρατηγική ρύθμισης του learning rate: ReduceLROnPlateau. Ο στόχος είναι να μειώνεται αυτόματα το learning rate όταν η απόδοση στο validation set σταθεροποιείται, με σκοπό να δοθεί χρόνος στο μοντέλο να συγκλίνει σε καλύτερα ελάχιστα. Ωστόσο, και σε αυτή την περίπτωση:

- **F1-score** = 0.8525
- **Accuracy** = 0.8525

δεν παρατηρήθηκε κάποια βελτίωση.

– Πειράματα distilBERT

Trial	Learning Rate	Batch Size	Weight Decay	Hidden Dropout	Attention Dropout	Classification Dropout	Scheduler
1	2e-5	16	-	-	-	-	Linear With Warmup
2	2e-5	32	-	-	-	-	Linear With Warmup
3	2e-5	64	-	-	-	-	Linear With Warmup
4	2e-5	96	-	-	-	-	Linear With Warmup
5	1e-5	16	-	-	-	-	Linear With Warmup
6	4e-5	16	-	-	-	-	Linear With Warmup
7	1e-4	16	-	-	-	-	Linear With Warmup
8	1e-5	16	-	-	-	-	Linear With Warmup
9	1e-5	16	0.25	0.3	0.07	0.001	Linear With Warmup
10	1e-5	16	0.5	0.3	0.07	0.001	Linear With Warmup
11	1e-5	16	0.02	0.3	0.07	0.001	Linear With Warmup
12	1e-5	16	0.5	0.3	0.21	0.001	Linear With Warmup
13	1e-5	16	0.5	0.3	0.01	0.001	Linear With Warmup
14	1e-5	16	0.5	0.3	0.07	0.01	Linear With Warmup
15	1e-5	16	0.5	0.3	0.07	1e-4	Linear With Warmup
16	1e-5	16	0.5	0.15	0.07	0.001	Linear With Warmup
17	1e-5	16	0.5	0.5	0.07	0.001	Linear With Warmup
18	1e-5	16	0.5	0.3	0.07	0.001	CAWR
19	1e-5	16	0.5	0.3	0.07	0.001	Reduce LR on Plateu

Table 3: Παράμετροι πειραμάτων distilBERT

**CAWR = Cosine Annealing with Warm Restarts

Trial	Phase	Loss	Accuracy	F1	Recall	Precision
1	Train	0.2961	0.8767	0.8767	0.8767	0.8767
1	Validation	0.3632	0.8461	0.8461	0.8461	0.8463
2	Train	0.3033	0.8723	0.8723	0.8723	0.8723
2	Validation	0.3576	0.8459	0.8459	0.8459	0.8459
3	Train	0.2631	0.8915	0.8915	0.8915	0.8915
3	Validation	0.3756	0.8458	0.8458	0.8458	0.8459
4	Train	0.2795	0.8830	0.8830	0.8830	0.8830
4	Validation	0.3684	0.8459	0.8459	0.8459	0.8459
5	Train	0.3226	0.8638	0.8638	0.8638	0.8638
5	Validation	0.3568	0.8469	0.8470	0.8469	0.8470
6	Train	0.1885	0.9338	0.9338	0.9338	0.9338
6	Validation	0.5306	0.8410	0.8409	0.8410	0.8410
7	Train	0.2576	0.9040	0.9040	0.9040	0.9040
7	Validation	0.5005	0.8263	0.8263	0.8263	0.8263
8	Train	0.2750	0.8885	0.8885	0.8885	0.8886
8	Validation	0.3887	0.8472	0.8472	0.8472	0.8472
9	Train	0.2743	0.8887	0.8887	0.8887	0.8887
9	Validation	0.3883	0.8473	0.8473	0.8473	0.8473
10	Train	0.2762	0.8877	0.8876	0.8876	0.8876
10	Validation	0.3857	0.8477	0.8477	0.8477	0.8478
11	Train	0.3225	0.8637	0.8637	0.8637	0.8635
11	Validation	0.3567	0.8469	0.8469	0.8469	0.8469
12	Train	0.2762	0.8876	0.8876	0.8876	0.8876
12	Validation	0.3857	0.8477	0.8477	0.8477	0.8478
13	Train	0.2762	0.8876	0.8876	0.8876	0.8876
13	Validation	0.3857	0.8477	0.8477	0.8477	0.8478
14	Train	0.2762	0.8876	0.8876	0.8876	0.8877
14	Validation	0.3857	0.8477	0.8477	0.8477	0.8477
15	Train	0.2762	0.8876	0.8876	0.8876	0.8876
15	Validation	0.3857	0.8477	0.8477	0.8477	0.8478

16	Train	0.2762	0.8876	0.8876	0.8876	0.8876
16	Validation	0.3857	0.8477	0.8477	0.8477	0.8478
17	Train	0.2762	0.8876	0.8876	0.8876	0.8876
17	Validation	0.3857	0.8477	0.8477	0.8477	0.8478
18	Train	0.2837	0.8844	0.8844	0.8844	0.8846
18	Validation	0.3759	0.8439	0.8439	0.8439	0.8442
19	Train	0.3272	0.8612	0.8612	0.8612	0.8612
19	Validation	0.3546	0.8439	0.8439	0.8439	0.8439

Table 4: Μετρικές πειραμάτων distilBERT 1) Πείραμα 1

Αντίστοιχα με το BERT και εδώ στα πρώτα πειράματα δοκιμάστηκε ένα απλό μοντέλο στο οποίο ρυθμίστηκαν πρώτα το learning rate και το batch size, για να βρούμε τον συνδυασμό τιμών αυτών των παραμέτρων που παραχωρούν τόσο μια καλή συμπεριφορά μάθησης, όσο και μια καλή ευστοχία του μοντέλου στις προβλέψεις.

Ξεκινάμε με batch_size = 16 και το στάνταρ learning_rate 2e-5. Για αρχή το μοντέλο παρουσιάζει ήδη ένα καλό accuracy στο 2ο epoch και δεν παρουσιάζει τάση προς overfitting.

Loss και Learning Curve:

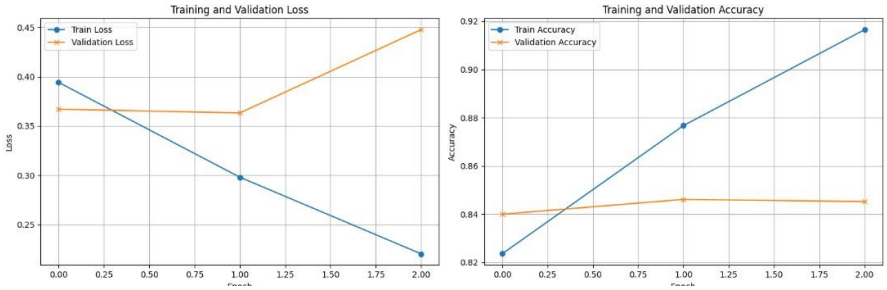

Figure 15: Πείραμα 1, Loss and Learning Curve

Confusion Matrix:

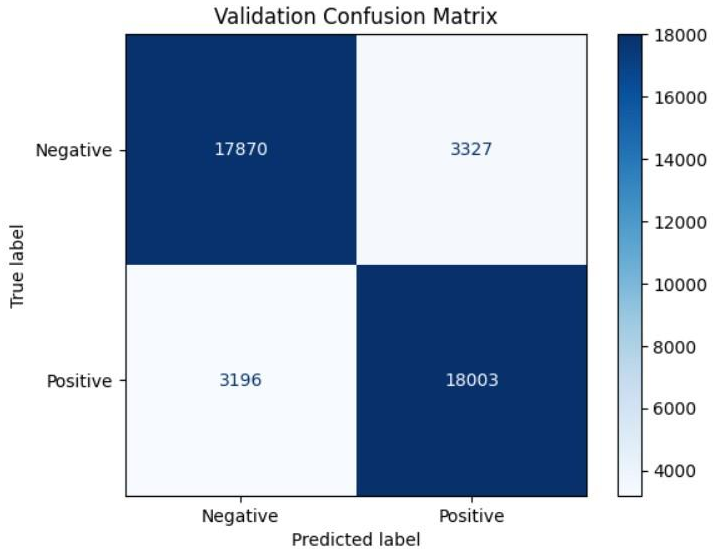

Figure 16: Πείραμα 1, Confusion Matrix

ROC curve:

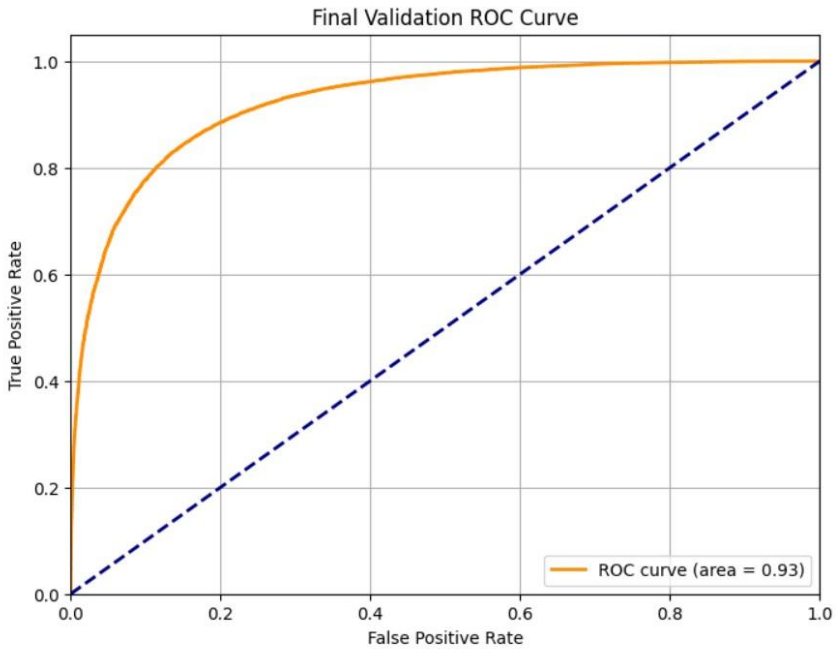

Figure 17: Πείραμα 1, ROC curve

2) Πείραμα 2

Εδώ διατηρούμε το ίδιο learning rate αλλά διπλασιάζουμε το batch size και το θέτουμε ίσο με 32. ΄Οπως και στα πειράματα του BERT, έτσι και εδώ στο distilBERT βλέπουμε μικρή μείωση της διαφοράς μάθησης ανάμεσα σε training και validation, αλλά παράλληλα υπάρχει μικρή πτώση στην ευστοχία του μοντέλου. Loss και Learning Curve:

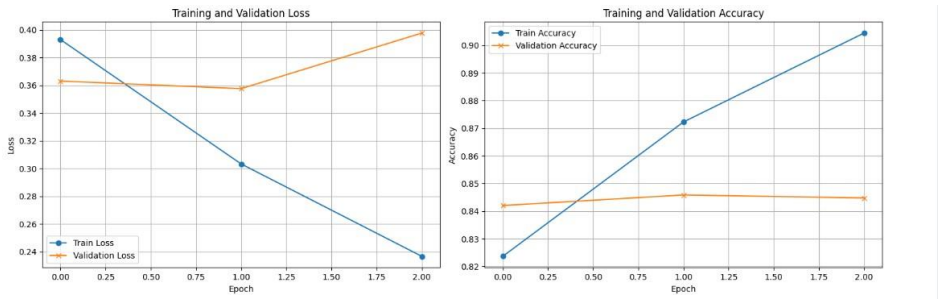

Figure 18: Πείραμα 2, Loss and Learning Curve

Confusion Matrix:

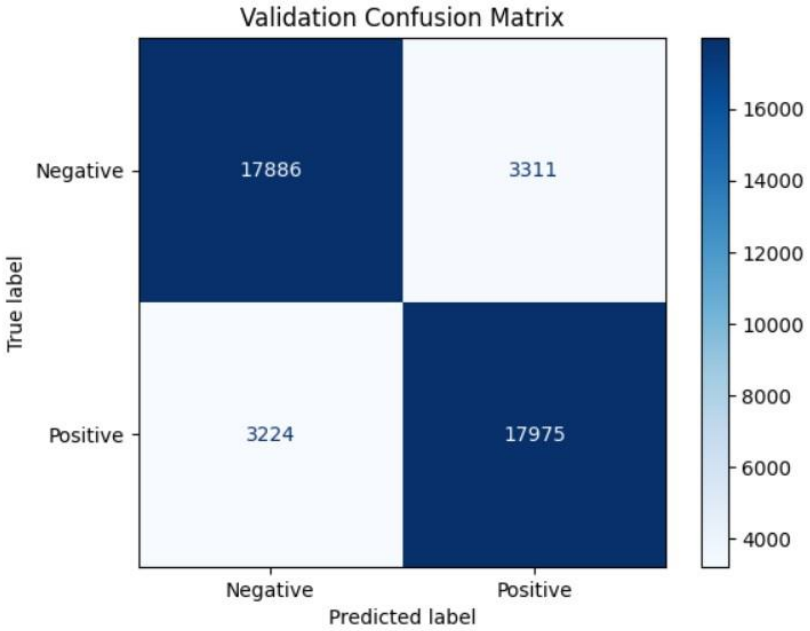

Figure 19: Πείραμα 2, Confusion Matrix

ROC curve:

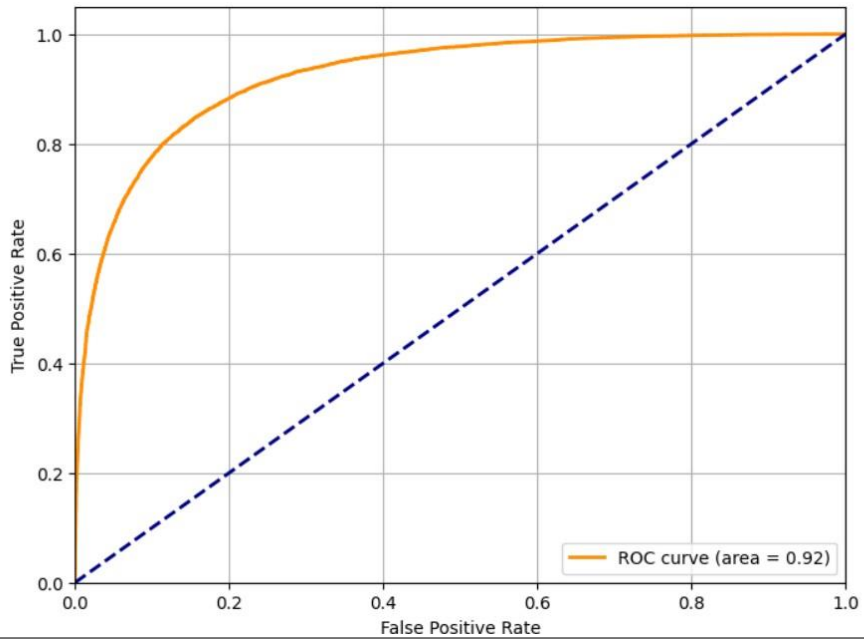

Figure 20: Πείραμα 2, ROC curve

3) Πείραμα 3

Σε αυτό το πείραμα αυξάνουμε την τιμή του batch_size σε 64, διατηρώντας σταθερή την τιμή του learning rate στο 2e-5, χωρίς ακόμη να εφαρμόζεται weight decay ή κάποιο dropout.

Το μοντέλο παρουσίασε λίγο μειωμένες επιδόσεις στις μετρικές του training set , ενώ ταυτόχρονα διατηρήθηκε η επίδοση στο validation set σε καλό επίπεδο. Η συμπεριφορά μάθησης ήταν πιο σταθερή σε σύγκριση με τα Πειράματα 1 και 2, ενώ παρατηρήθηκε ελαφρώς χαμηλότερο training loss, γεγονός που δείχνει πιο αποδοτική εκμάθηση. Ωστόσο, η γενική απόδοση του μοντέλου στο validation δεν βελτιώθηκε σε σχέση με πείραμα 1. Loss και Learning Curve:

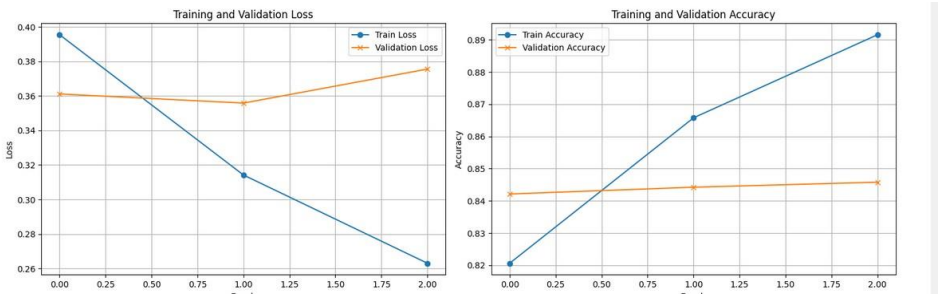

Figure 21: Πείραμα 3 (DistilBERT), Loss and Learning Curve

Confusion Matrix:

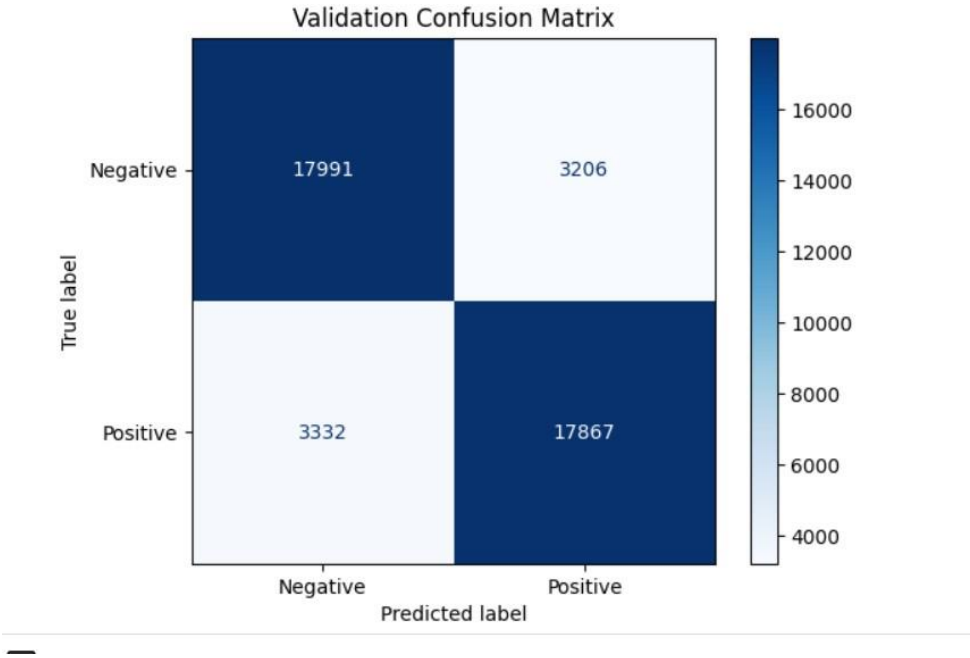

Figure 22: Πείραμα 3 (DistilBERT), Confusion Matrix

ROC curve:

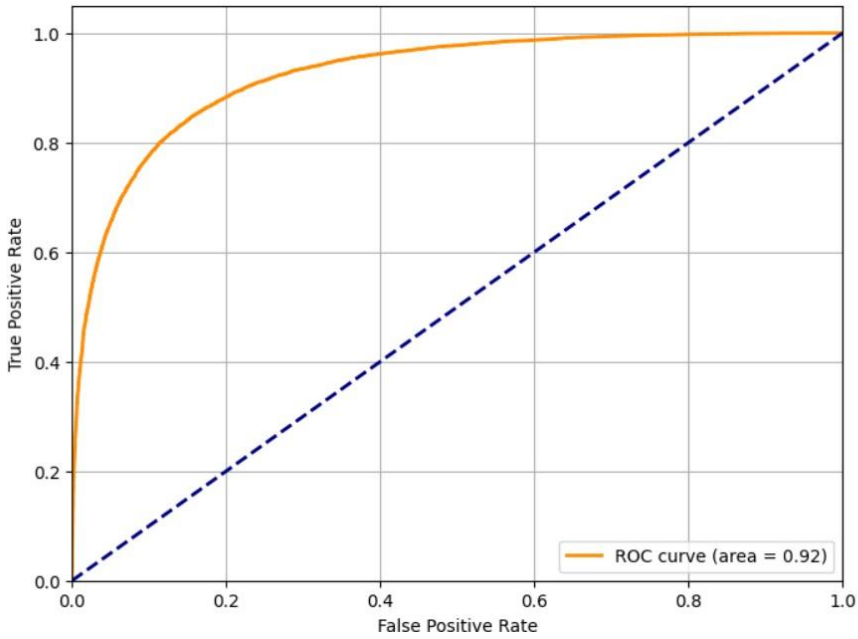

Figure 23: Πείραμα 3 (DistilBERT), ROC curve

4) Πείραμα 4

Στο Πείραμα 4 διατηρείται το learning rate = 2e-5, ενώ το batch_size αυξάνεται στο 96, ακολουθώντας την τάση των προηγούμενων πειραμάτων. Δεν εφαρμόζεται ακόμα κάποιο είδος regularization (dropout ή weight decay), με στόχο να παρατηρηθεί η συμπεριφορά του μοντέλου αποκλειστικά ως προς την αλλαγή batch size.

Τα αποτελέσματα έδειξαν πως η σταθερότητα της εκπαίδευσης παρέμεινε σε υψηλό επίπεδο, ενώ αν και οι μετρικές του validation set παρέμειναν πρακτικά αμετάβλητες σε σχέση με το Πείραμα 3, δεν παρουσίασαν βελτίωση σε σχέση. Το training loss συνέχισε να μειώνεται, γεγονός που υποδηλώνει σταδιακή προσαρμογή του μοντέλου στα δεδομένα. Ωστόσο, η απόδοση στο validation set δεν βελτιώθηκε, γεγονός που δείχνει ότι η αύξηση του batch size από 64 σε 96 δεν προσέφερε ουσιαστικό πλεονέκτημα. Loss και Learning Curve:

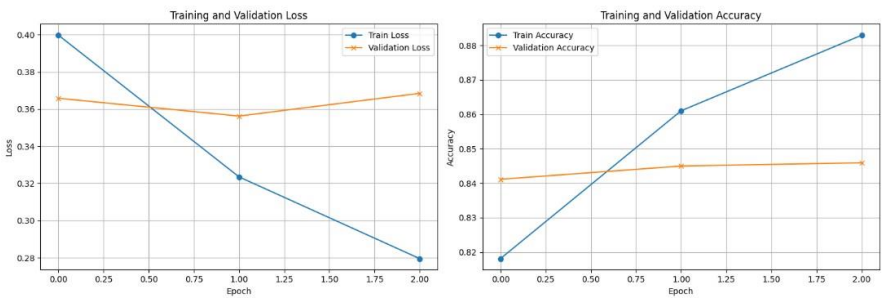

Figure 24: Πείραμα 4 (DistilBERT), Loss and Learning Curve

Confusion Matrix:

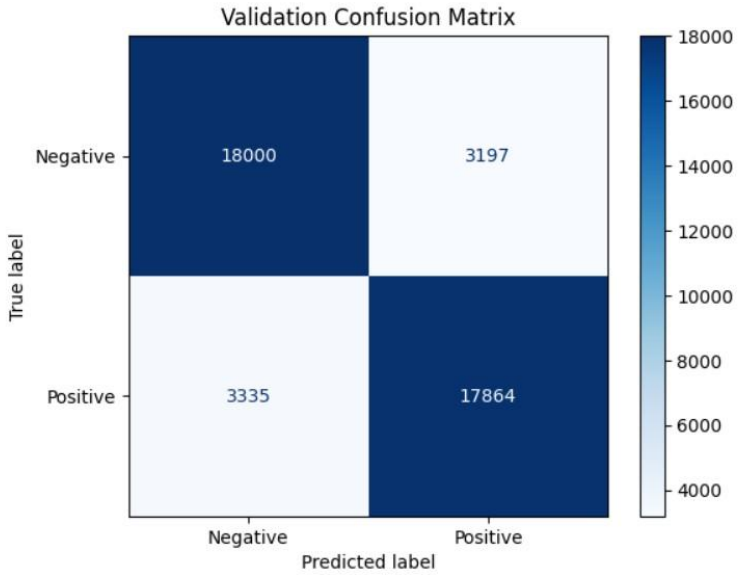

Figure 25: Πείραμα 4 (DistilBERT), Confusion Matrix

ROC curve:

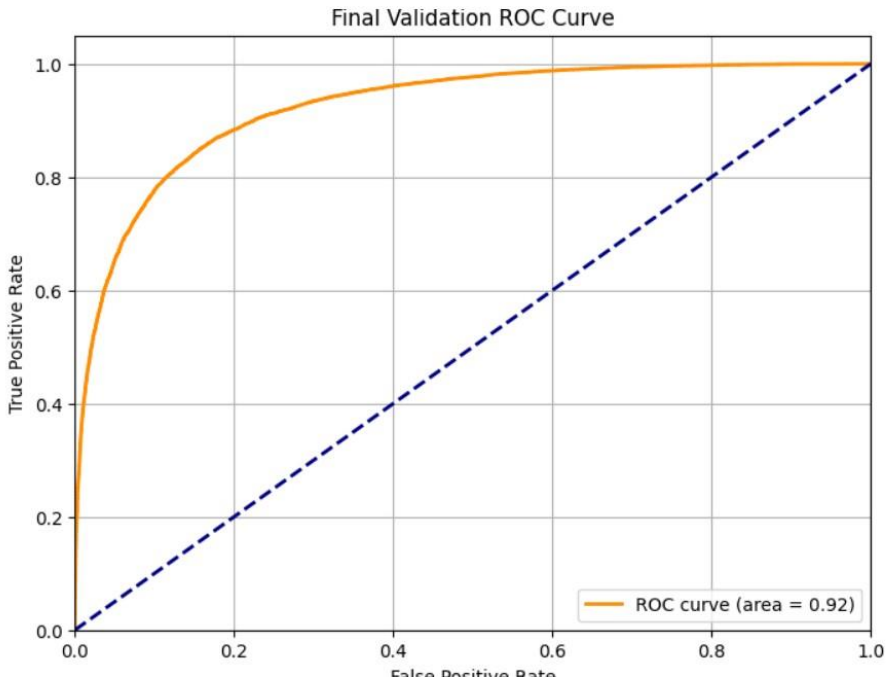

Figure 26: Πείραμα 4 (DistilBERT), ROC curve

5) Πείραμα 5

Στο Πείραμα 5, μειώνουμε το learning rate σε 1e-5, και επαναφέρουμε το batch_size στην τιμή 16, με την οποία παρουσιάστηκε η καλύτερη ευστοχία.

Από την ανάλυση των αποτελεσμάτων παρατηρείται μικρή αύξηση της απόδοσης στο validation set, με σταθερότητα και χωρίς ενδείξεις overfitting και μικρότερη απόκλιση training

και validation. Παρά τη σχετική αύξηση του training loss, οι επιδόσεις στο validation επιβεβαιώνουν ότι η εκπαίδευση έγινε πιο «προσεκτικά» και οδήγησε σε καλύτερη ισορροπία. Η μείωση του batch size σε αυτό το σημείο κρίθηκε θετική και αξιοποιήθηκε σε επόμενα πειράματα με πιο σύνθετο regularization. Loss και Learning Curve:

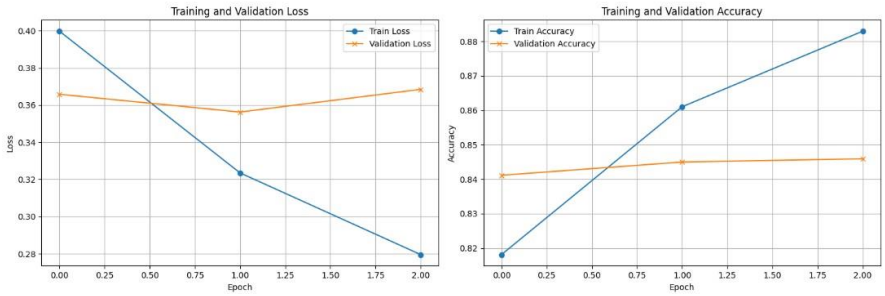

Figure 27: Πείραμα 5 (DistilBERT), Loss and Learning Curve

Confusion Matrix:

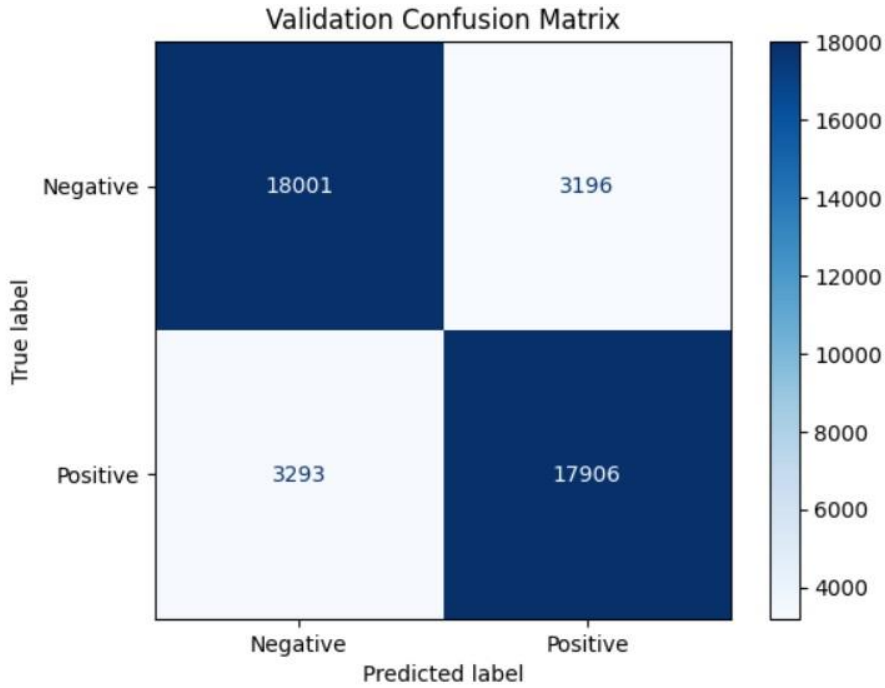

Figure 28: Πείραμα 5 (DistilBERT), Confusion Matrix

ROC curve:

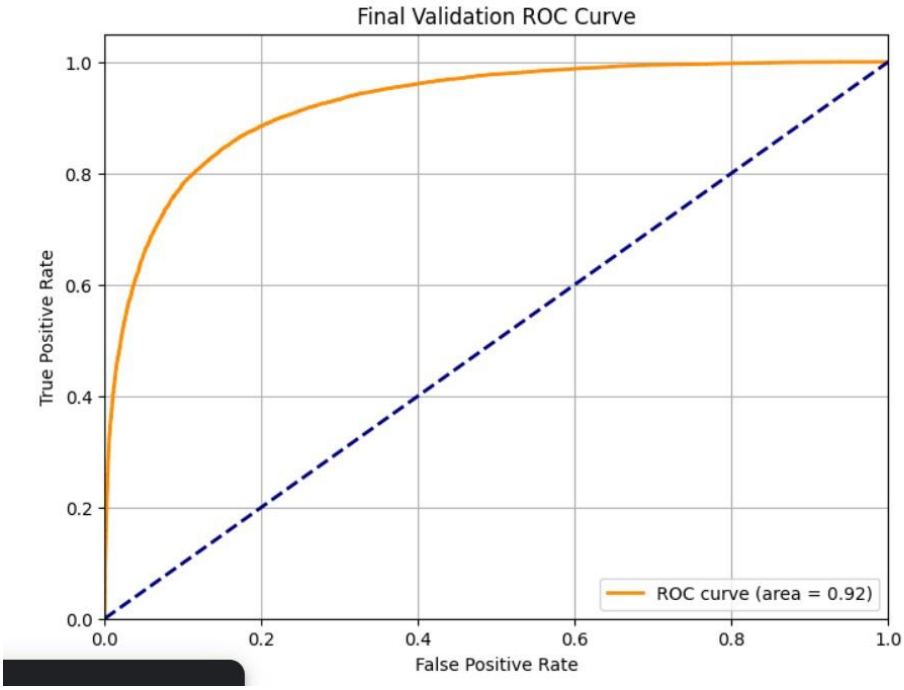

Figure 29: Πείραμα 5 (DistilBERT), ROC curve

6) Πείραμα 6

Στο Πείραμα 6 πραγματοποιείται σημαντική αύξηση του learning rate σε 4e-5, διατηρώντας τις υπόλοιπες παραμέτρους σταθερές (batch size = 16 και χωρίς επιπλέον regularization).
Στόχος του πειράματος ήταν να αξιολογηθεί η επίδραση ενός πιο επιθετικού ρυθμού μάθησης στην ταχύτητα και σταθερότητα της εκπαίδευσης.

΄Οπως αναμενόταν, το μοντέλο εμφάνισε πολύ χαμηλό training loss, ωστόσο συνοδεύτηκε από σαφώς αυξημένο **validation loss**, γεγονός που υποδηλώνει έντονο **overfitting**. Οι μετρικές στο validation dataset μειώθηκαν αισθητά, γεγονός που επιβεβαιώνει ότι το υψηλό learning rate δεν επέτρεψε στο μοντέλο να προσαρμοστεί επαρκώς στη γενίκευση, οδηγώντας σε υποβάθμιση της συνολικής απόδοσης. Το πείραμα θεωρείται αποτυχημένο και απορρίφθηκε ως επιλογή για τις επόμενες δοκιμές. Loss και Learning Curve:

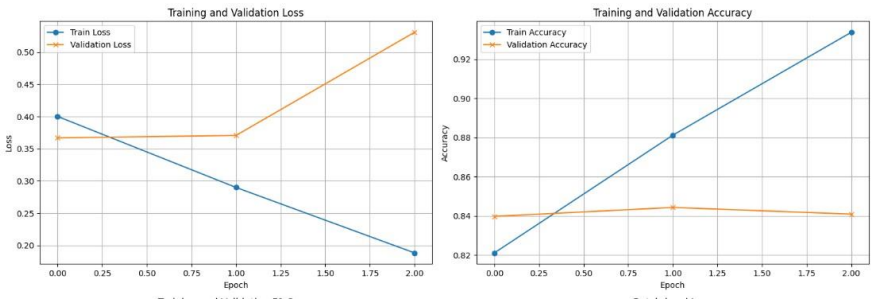

Figure 30: Πείραμα 6 (DistilBERT), Loss and Learning Curve

Confusion Matrix:

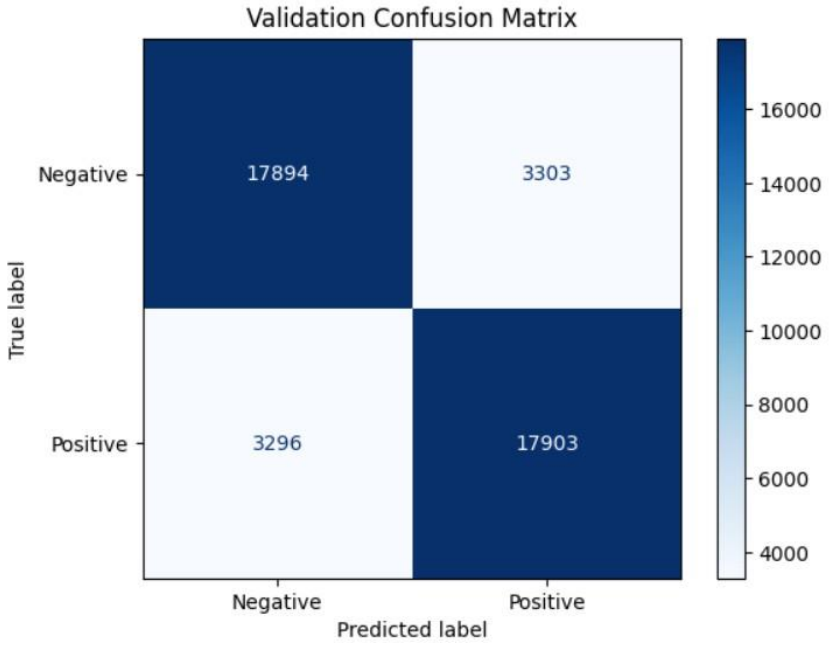

Figure 31: Πείραμα 6 (DistilBERT), Confusion Matrix

7) Πείραμα 7

Στο Πείραμα 7 αυξάνεται ακόμη περισσότερο το learning rate σε 1e-4, ενώ οι υπόλοιπες παράμετροι διατηρούνται ως έχουν (batch size = 16 και χωρίς weight decay ή dropouts).
Σκοπός είναι να διερευνηθεί το πώς ανταποκρίνεται το μοντέλο σε έναν πολύ υψηλό ρυθμό μάθησης.

Το αποτέλεσμα ήταν ιδιαίτερα αρνητικό. Παρά το πολύ χαμηλό training loss, η απόδοση στο validation set μειώθηκε σημαντικά, υποδεικνύοντας σοβαρό **overfitting** και αποσταθεροποίηση της εκπαίδευσης. Το μοντέλο προσαρμόστηκε υπερβολικά στο training set, εις βάρος της ικανότητάς του να γενικεύει σε άγνωστα δεδομένα. Το πείραμα αξιολογείται ως αποτυχία και αποκλείεται από περαιτέρω ανάλυση.

8) Πείραμα 8

Εδώ έγινε η εφαρμογή του optuna, ώστε να καθορίσουμε κάποιες βοηθητικές τιμές για τις παραμέτρους weight decay, attention dropout, hidden dropout και classification dropout.

Αναδείχθηκαν ως βέλτιστες οι τιμές:

- **weight decay** = 0.25
- **attention dropout** = 0.07
- **hidden dropout** = 0.3

- **classifier dropout** = 0.001

9) Πείραμα 9

Στο Πείραμα 9 χρησιμοποιούνται οι τιμές των υπερπαραμέτρων που πρότεινε το Optuna στο Πείραμα 8, χωρίς καμία τροποποίηση. Δηλαδή:

- weight_decay = 0.25
- hidden_dropout = 0.3
- attention_dropout = 0.07
- classifier_dropout = 0.001

Σκοπός του πειράματος ήταν να επαληθευτεί η αξιοπιστία της αυτόματης επιλογής παραμέτρων σε ένα πλήρες training run. Το μοντέλο παρουσίασε σταθερή συμπεριφορά και αρκετά καλή επίδοση στο validation set, χωρίς εμφανή σημάδια overfitting. Παρότι η συνολική απόδοση δεν βελτιώθηκε σημαντικά σε σχέση με το Πείραμα 8, επιβεβαιώθηκε ότι η παραμετροποίηση του Optuna αποτελεί μια αξιόπιστη αφετηρία για περαιτέρω fine-tuning.

10) Πείραμα 10

Στο Πείραμα 10 επιχειρείται μια τροποποίηση του Πειράματος 9 με στόχο την ενίσχυση του regularization. Συγκεκριμένα, αυξάνεται το **weight decay** από **0.25** σε **0.5**, ενώ όλες οι υπόλοιπες παράμετροι παραμένουν αμετάβλητες.

Η αλλαγή αυτή είχε ως αποτέλεσμα μικρή αλλά σαφή βελτίωση της απόδοσης στο **validation set**, γεγονός που δείχνει ότι η ενίσχυση του weight decay βοήθησε στην περαιτέρω αποφυγή υπερπροσαρμογής. Το training loss παρέμεινε σταθερό, ενώ η συνολική συμπεριφορά του μοντέλου διατηρήθηκε ομαλή. Η δοκιμή αυτή επιβεβαιώνει ότι μια πιο επιθετική ρύθμιση του weight decay μπορεί να έχει θετική επίδραση με τον τρόπο που έχει διαμορφωθεί το μοντέλο ως τώρα.

11) Πείραμα 11

Στο Πείραμα 11 ελέγχεται η επίδραση της περαιτέρω μείωσης του weight decay, το οποίο περιορίζεται από 0.25 σε 0.02, με στόχο να διαπιστωθεί αν η ασθενέστερη κανονικοποίηση θα οδηγήσει σε καλύτερη εκμάθηση των χαρακτηριστικών.

Ωστόσο, το αποτέλεσμα δεν ήταν θετικό. Το μοντέλο εμφάνισε ελαφρώς αυξημένη απόδοση στο training set αλλά χωρίς κάποια βελτίωση στο **validation set**, γεγονός που δείχνει ότι η μειωμένη τιμή του weight decay μείωσε το regularization χωρίς ουσιαστικό όφελος στη

γενίκευση. Συνεπώς, το πείραμα αυτό αξιολογήθηκε ως ουδέτερο ή ελαφρώς υποδεέστερο από τα προηγούμενα.

12) Πείραμα 12

Στο Πείραμα 12 επανέρχεται το weight_decay = 0.5, τιμή την οποία επιλέγουμε και για τα παρακάτω πειράματα, ενώ τροποποιείται η τιμή του attention dropout από 0.07 σε 0.21, με σκοπό να εξεταστεί η επίδραση της αύξησης του dropout σε αυτό το επίπεδο.

Η αλλαγή αυτή δεν οδήγησε σε βελτίωση. Η επίδοση του μοντέλου στο validation set παρέμεινε σχεδόν αμετάβλητη, γεγονός που υποδηλώνει ότι η αύξηση του attention dropout δεν προσέφερε επιπλέον regularization ή όφελος στη γενίκευση. Το αποτέλεσμα ήταν αντίστοιχο του Πειράματος 10 και το πείραμα δεν αξιολογήθηκε ως βελτίωση.

13) Πείραμα 13

Στο Πείραμα 13 διατηρούνται σταθερές όλες οι υπόλοιπες υπερπαράμετροι, αλλά μειώνεται το attention dropout από 0.21 σε 0.01. Η επιλογή αυτή έχει στόχο να ελεγχθεί αν λιγότερο dropout στη φάση της προσοχής μπορεί να επιτρέψει στο μοντέλο να διατηρήσει περισσότερη πληροφορία κατά την εκπαίδευση.

Ωστόσο, όπως και στο προηγούμενο πείραμα, δεν παρατηρήθηκε αξιοσημείωτη διαφοροποίηση στην επίδοση του μοντέλου. Το αποτέλεσμα υποδηλώνει ότι, εντός των ορίων αυτών των τιμών, το attention dropout δεν επηρεάζει δραστικά την τελική απόδοση. Το πείραμα δεν κρίθηκε ως βελτίωση.

14) Πείραμα 14

Στο Πείραμα 14 μεταβάλλεται η τιμή του classifier dropout, αυξάνοντάς την από 0.001 σε 0.01, με στόχο να αξιολογηθεί αν ένα ελαφρώς υψηλότερο dropout στην τελική ταξινομητική στρώση μπορεί να βελτιώσει τη γενίκευση του μοντέλου. Οι υπόλοιπες υπερπαράμετροι παραμένουν ίδιες.

Η μεταβολή αυτή δεν είχε ουσιαστική επίδραση στην απόδοση του μοντέλου. Οι μετρικές στο validation set παρέμειναν πρακτικά αμετάβλητες σε σχέση με τα προηγούμενα πειράματα. Αυτό υποδηλώνει ότι το classifier dropout, τουλάχιστον σε αυτό το εύρος τιμών, δεν αποτελεί κρίσιμο παράγοντα για την απόδοση του DistilBERT στο συγκεκριμένο task.

15) Πείραμα 15

Στο Πείραμα 15 δοκιμάζεται μια μεγαλύτερη τιμή για το classifier dropout, μειώνοντάς το από 0.01 σε 1e-4 (δηλαδή 0.0001). Η αλλαγή αυτή έχει στόχο να ελεγχθεί αν ένα εξαιρετικά μικρό dropout στην ταξινομητική στρώση μπορεί να έχει θετικό ή αρνητικό αντίκτυπο στη συμπεριφορά του μοντέλου.

Ωστόσο, και σε αυτή την περίπτωση, η αλλαγή στο classifier dropout δεν επέφερε αξιοσημείωτες διαφοροποιήσεις στις μετρικές του validation set. Η σταθερότητα των αποτελεσμάτων δείχνει ότι η συγκεκριμένη παράμετρος έχει περιορισμένη επιρροή στο τελικό performance, τουλάχιστον στο συγκεκριμένο εύρος τιμών που δοκιμάστηκε.

16) Πείραμα 16

Στο Πείραμα 16 μεταβάλλεται η τιμή του hidden dropout, η οποία μειώνεται από 0.3 σε 0.15, ενώ όλες οι υπόλοιπες υπερπαράμετροι (learning rate, weight decay, attention και classifier dropout) παραμένουν σταθερές.

Ο στόχος ήταν να εξεταστεί αν λιγότερο dropout στις εσωτερικές στρώσεις του μοντέλου μπορεί να επιτρέψει πιο αποδοτική μάθηση, χωρίς να θυσιάζεται η ικανότητα γενίκευσης. Το αποτέλεσμα του πειράματος επιβεβαίωσε αυτή την υπόθεση, καθώς το μοντέλο διατήρησε την ίδια σταθερή απόδοση όπως και στα προηγούμενα πειράματα. Δεν παρατηρήθηκε υποχώρηση στις μετρικές, γεγονός που δείχνει ότι η μείωση του hidden dropout δεν επηρέασε αρνητικά τη γενίκευση.

17) Πείραμα 17

Στο Πείραμα 17 εξετάζεται η επίδραση αύξησης του **hidden dropout** σε 0.5, δηλαδή στο ανώτερο εύρος των τιμών που δοκιμάστηκαν. ΄Ολες οι υπόλοιπες υπερπαράμετροι διατηρούνται ίδιες με το Πείραμα 16.

Ο στόχος ήταν να διαπιστωθεί αν έντονο regularization μέσω dropout θα βοηθήσει στη μείωση της υπερεκπαίδευσης και σε πιθανή βελτίωση της γενίκευσης. Ωστόσο, το αποτέλεσμα έδειξε ότι η επίδοση του μοντέλου δεν παρουσίασε καμία βελτίωση και παρέμεινε πανομοιότυπη με αυτή του προηγούμενου πειράματος.

Αυτό δείχνει ότι η αύξηση του dropout στις εσωτερικές στρώσεις πέρα από ένα όριο δεν προσφέρει επιπλέον οφέλη και πιθανώς περιορίζει την εκμάθηση σημαντικών χαρακτηριστικών.

18) Πείραμα 18

Στο Πείραμα 18 δοκιμάζεται η χρήση του scheduler Cosine Annealing with Warm Restarts (CAWR), διατηρώντας σταθερές τις υπόλοιπες υπερπαραμέτρους. Ο στόχος ήταν να ελεγχθεί αν η κυκλική μείωση και επανεκκίνηση του learning rate θα μπορούσε να συμβάλει σε πιο αποτελεσματική εκμάθηση.

Ωστόσο, η επίδοση του μοντέλου στο validation set παρέμεινε πρακτικά αμετάβλητη σε σχέση με προηγούμενα πειράματα, υποδηλώνοντας ότι το συγκεκριμένο scheduler δεν πρόσφερε ουσιαστικό πλεονέκτημα σε αυτό το setup. Επομένως, η επιλογή ενός πιο απλού

scheduler, όπως το Linear Warmup, εξακολουθεί να αποτελεί πιο αξιόπιστη λύση για το συγκεκριμένο μοντέλο και πρόβλημα.

19) Πείραμα 19

Το Πείραμα 19 αξιολογεί την τεχνική ReduceLROnPlateau ως scheduler, με στόχο να μειωθεί το learning rate αυτόματα όταν η απόδοση στο validation set δεν βελτιώνεται. Οι υπόλοιπες υπερπαράμετροι διατηρήθηκαν ίδιες με προηγούμενα πειράματα, ώστε να εξεταστεί μεμονωμένα η επίδραση αυτής της στρατηγικής.

Τα αποτελέσματα έδειξαν ότι η συγκεκριμένη τεχνική δεν οδήγησε σε σημαντική βελτίωση στην απόδοση του μοντέλου. Αν και το μοντέλο διατήρησε σταθερή συμπεριφορά, η ReduceLROnPlateau δεν φάνηκε να παρέχει κάποιο ιδιαίτερο πλεονέκτημα έναντι της απλής Linear Warmup. ΄Ετσι, η χρήση της δεν προτιμήθηκε στις τελικές ρυθμίσεις.

3.1. Hyper-parameter tuning

Η διαδικασία ρύθμισης υπερπαραμέτρων έγινε τόσο χειροκίνητα, βάσει επαναληπτικών πειραμάτων, όσο και με τη χρήση εργαλείων όπως το Optuna, με το οποίο καθορίστηκαν και στα δύο μοντέλα με όσο το δυνατό καλύτερες προσεγγίσεις οι τιμές των weight decay, attention dropout, hidden layer dropout και classification dropout. Στόχος ήταν η βελτιστοποίηση της απόδοσης του μοντέλου στο validation set. Δοκιμάστηκαν διαφορετικές τιμές για τις παραμέτρους learning rate, batch size, weight decay και dropout, όπως παρουσιάζονται αναλυτικά στους Πίνακες 1 και 3 για τα μοντέλα BERT και DistilBERT.

Στην περίπτωση του BERT, η τιμή learning rate = 4e-5 σε συνδυασμό με batch size = 96 και dropout 0.15 στις διάφορες στρώσεις παρείχε τη βέλτιστη απόδοση (Trial 16). Η χρήση weight decay = 0.065 βοήθησε σημαντικά στην αποφυγή overfitting, καθώς παρατηρήθηκε μείωση του validation loss χωρίς επιδείνωση του accuracy.

Για το DistilBERT, το βέλτιστο setup επιτεύχθηκε με learning rate = 1e-5 και μικρότερο batch size = 16, ώστε να διατηρείται η σταθερότητα του training. Η εισαγωγή dropout σε attention, hidden και classification layers ώθησε σε καλύτερη γενίκευση του μοντέλου στο training, ενώ το weight decay = 0.5 αποδείχθηκε ιδιαίτερα αποτελεσματικό στο regularization.

Σε αρκετές περιπτώσεις δοκιμών, παρατηρήθηκαν φαινόμενα underfitting (χαμηλή απόδοση σε train και val) για πολύ χαμηλά learning rates ή πολύ υψηλό dropout, καθώς και overfitting όταν το dropout/weight decay ήταν μηδενικό. Η επιλογή hyper-parameters έγινε τελικά βάσει της επίδοσης στο accuracy και της σταθερότητας της εκπαίδευσης σε 3 epochs.

΄Ολα τα πειράματα εκτελέστηκαν με χρήση 3 epochs για το training.

3.2. Optimization techniques

Κατά την εκπαίδευση των μοντέλων εφαρμόστηκαν διάφορες τεχνικές για τη βελτίωση της σταθερότητας και της απόδοσης. Αρχικά, χρησιμοποιήθηκε ο βελτιωμένος αλγόριθμος AdamW για την προσαρμογή των βαρών του μοντέλου, ο οποίος είναι κατάλληλος για μοντέλα όπως το BERT και το DistilBERT. Ο συγκεκριμένος αλγόριθμος βοηθά στο να μη μαθαίνει το μοντέλο μεροληπτικά, εφαρμόζοντας μια μορφή regularization,

Για να ελέγχεται η ταχύτητα με την οποία το μοντέλο μαθαίνει, εφαρμόστηκε σταδιακή ρύθμιση του ρυθμού μάθησης (learning rate), ώστε να ξεκινά πιο αργά και να αυξάνεται ομαλά στην αρχή (warm-up), ενώ στη συνέχεια μειώνεται σταδιακά. Αυτό αποτρέπει έντονες διακυμάνσεις και οδηγεί σε πιο ομαλή εκπαίδευση, ειδικά στα πρώτα epochs.

Για επιπλέον βελτίωση, δοκιμάστηκαν εναλλακτικά σχήματα ρύθμισης του learning rate (schedulers), όπως το Cosine Annealing με επανεκκινήσεις (CAWR) και η αυτόματη μείωση όταν η απόδοση δεν βελτιώνεται (ReduceLROnPlateau). Παρόλο που αυτές οι μέθοδοι εμφάνισαν ενδιαφέροντα αποτελέσματα, τελικά το απλό σχήμα με σταδιακή γραμμική μείωση (linear warmup) ήταν το πιο αξιόπιστο και αυτό που παραχωρούσε την υψηλότερη επίδοση.

Επιπλέον, σε μεμονωμένα πειράματα χρησιμοποιήθηκε το εργαλείο Optuna για την αυτόματη ρύθμιση τιμών των παραμέτρων dropout και weight decay. Τα αποτελέσματα από τις δοκιμές με Optuna βοήθησαν στον καθορισμό αρχικών τιμών που χρησιμοποιήθηκαν στα τελικά πειράματα, στα οποία δοκιμάστηκαν τιμές για τα dropouts και η τιμή του weight decay.

3.3. Evaluation

Η αξιολόγηση των μοντέλων βασίστηκε στις μετρικές **accuracy**, **precision**, **recall** και **F1score** με στόχο μια πλήρη εικόνα της απόδοσης σε binary classification πρόβλημα. Επιπλέον, αξιοποιήθηκαν διαγράμματα όπως οι ROC curves και confusion matrices, για να αναλυθεί η συμπεριφορά των μοντέλων πέρα από τις συνοπτικές τιμές των μετρικών.

Συγκριτικά, το **BERT** εμφάνισε σταθερά ελαφρώς καλύτερες επιδόσεις από το **DistilBERT**, με μέγιστο accuracy 0.855 και AUC περίπου 0.93, ενώ το DistilBERT σταθεροποιήθηκε κοντά στο 0.848 σε accuracy και στο 0.92 σε AUC. Η διαφορά αυτή, αν και σχετικά μικρή, παρατηρείται με συνέπεια στα πειράματα και αντανακλά την πληρέστερη εκπαιδευτική ικανότητα του BERT, που έχει περισσότερες παραμέτρους και βαθύτερη αρχιτεκτονική.

Το DistilBERT, παρότι προσφέρει χαμηλότερη απόδοση, έχει μικρότερο χρόνο εκτέλεσης και χαμηλότερες απαιτήσεις σε υπολογιστικούς πόρους. Αυτό μπορεί να το καταστήσει κατάλληλο για σενάρια όπου η ταχύτητα και η αποδοτικότητα έχουν προτεραιότητα έναντι της μέγιστης ακρίβειας. Ωστόσο, στο πλαίσιο αυτής της εργασίας, η πλήρης fine-tuning διαδικασία του DistilBERT δεν κατάφερε να φτάσει την απόδοση του BERT, ιδίως σε περιπτώσεις πιο απαιτητικών παραμετρικών ρυθμίσεων.

Συνολικά, το BERT υπερέχει σε ακρίβεια και διαχωριστική ικανότητα, ενώ το DistilBERT προσφέρει μια εναλλακτική με χαμηλότερο υπολογιστικό κόστος, έστω με ελαφρώς περιορισμένη απόδοση.

4. Results and Overall Analysis

4.1. Results Analysis

Συνολικά, τα πειράματα και με τα δύο μοντέλα υπήρξαν αρκετά ικανοποιητικά, επιτυγχάνοντας υψηλές μετρικές απόδοσης και σταθερή συμπεριφορά στο validation set. Οι επιδόσεις τους ξεπερνούν συνήθως αυτές που παρατηρούνται σε παραδοσιακές προσεγγίσεις του ίδιου προβλήματος, όπως απλούστερα νευρωνικά δίκτυα ή μεθόδους με στατικά embeddings. Αυτό επιβεβαιώνει τη δυναμική των μοντέλων τύπου transformer στο sentiment analysis, ακόμα και σε απαιτητικά δεδομένα όπως τα tweets. Παρότι υπάρχουν περιθώρια βελτίωσης, ιδιαίτερα στη γενίκευση σε "δύσκολα" παραδείγματα, η συνολική εικόνα δείχνει ότι οι επιλογές preprocessing και fine-tuning απέδωσαν αποτελεσματικά.

4.1.1. Best trial. Οι καλύτερες επιδόσεις παρατηρήθηκαν στο Πείραμα **8** για το **BERT** και στο Πείραμα **11** για το **DistilBERT**. Επιπλέον, κατά την εκπαίδευση του μοντέλου BERT με τις παραμέτρους του πειράματος 8, διαπιστώθηκε ότι οι καλύτερες μετρικές στο **validation set** καταγράφηκαν στο δεύτερο **epoch**. Για το αντίστοιχο μοντέλο distilBERT, οι καλύτερες μετρικές παρουσιάστηκαν στο 3ο epoch, χωρίς να παρουσιάζει η ευστοχία στο training set μεγάλη διαφορά από αυτή του validation dataset, άρα κρατάμε την εκπαίδευση του μοντέλου distilBERT στα 3 epochs.

Εδώ παρατίθενται plots για το καλύτερο μοντέλο BERT: Loss και Learning Curve:

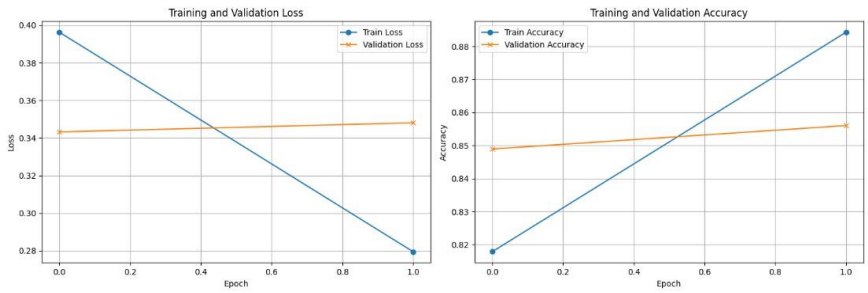

Figure 32: Καλύτερο Μοντέλο (BERT), Loss and Learning Curve

Confusion Matrix:

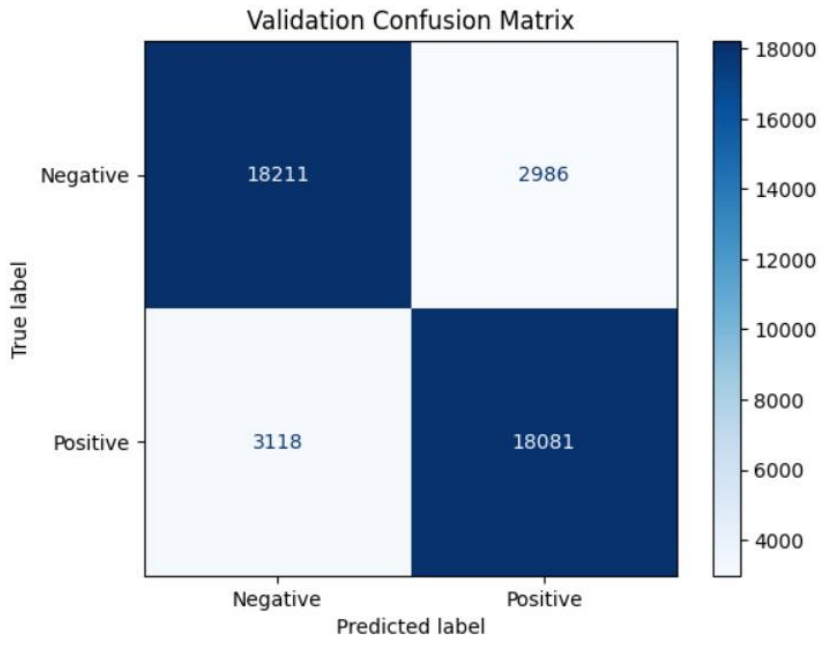

Figure 33: Καλύτερο Μοντέλο (BERT), Confusion Matrix

ROC curve:

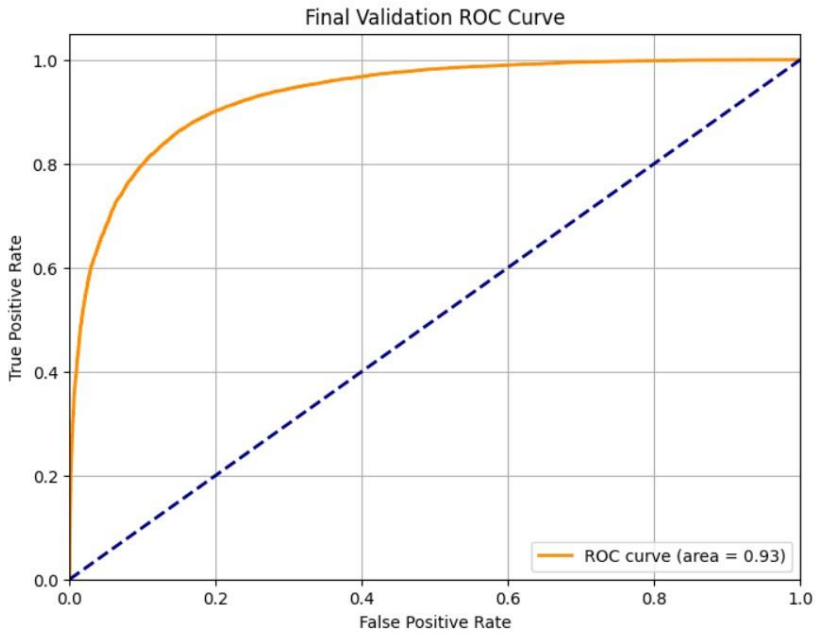

Figure 34: Καλύτερο Μοντέλο (BERT), ROC curve

Plots για καλύτερο μοντέλο distilBERT: Loss και Learning Curve:

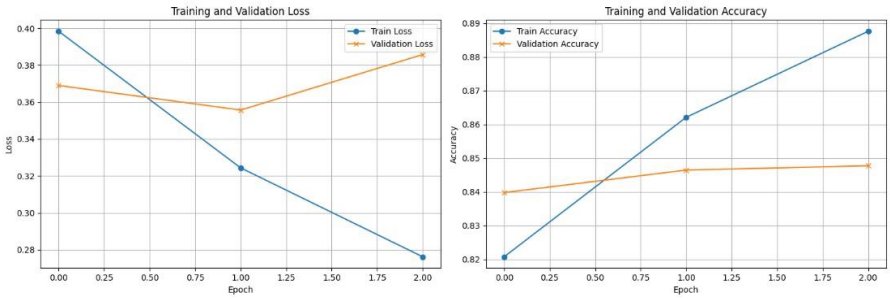

Figure 35: Καλύτερο Μοντέλο (distilBERT), Loss and Learning Curve

Confusion Matrix:

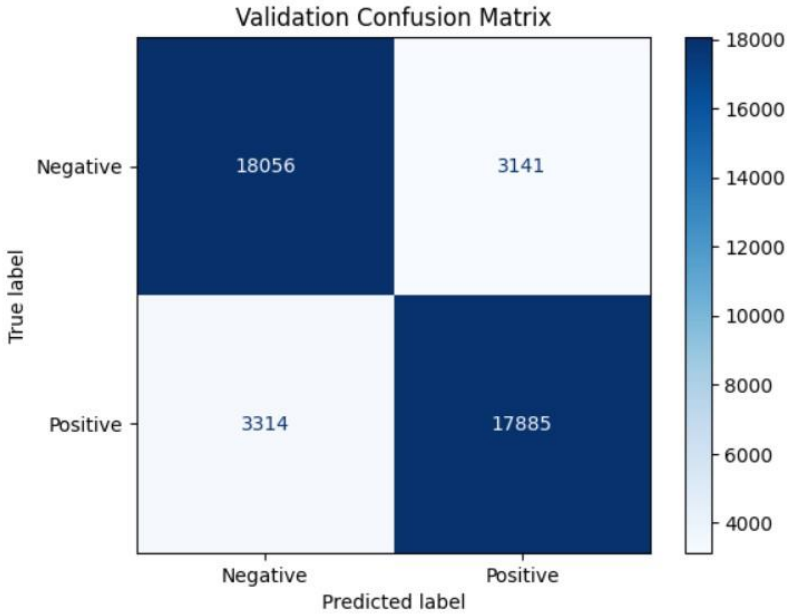

Figure 36: Καλύτερο Μοντέλο (distilBERT), Confusion Matrix

ROC curve:

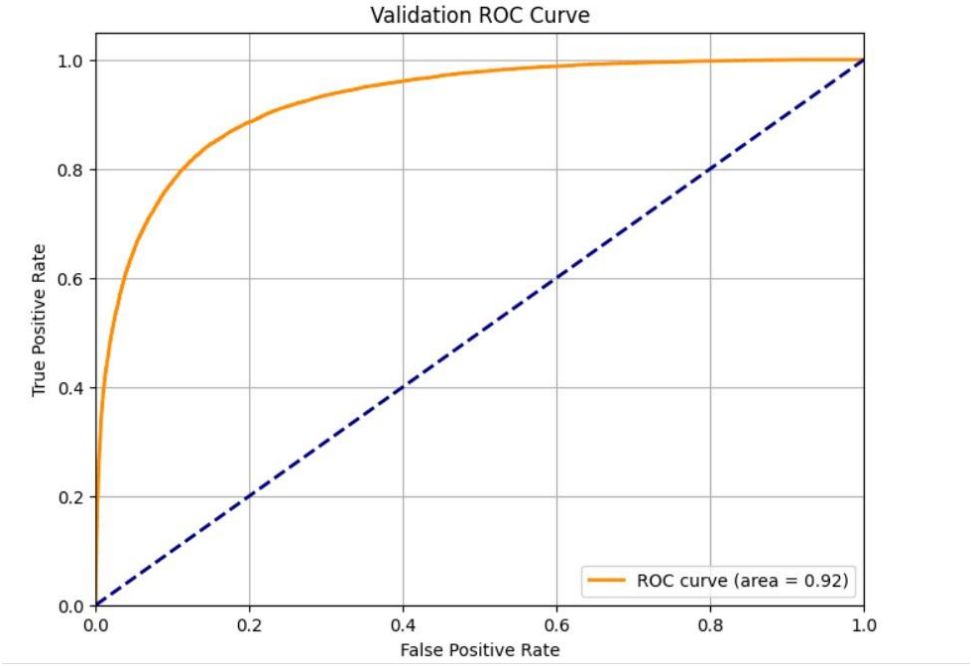

Figure 37: Καλύτερο Μοντέλο (distilBERT), ROC curve